

2024-01-03

動的個別化治療に向けたオフライン・  
オンライン強化学習の融合によるHIV投薬  
スケジュールの最適化

指導教員 大森 浩充 教授

慶應義塾大学理工学部

システムデザイン工学科

2024（令和6）年度 卒業論文

学籍番号 62121454

渡辺功侑

# 目次

|       |                                  |    |
|-------|----------------------------------|----|
| 第 1 章 | 序論                               | 2  |
| 1.1   | 研究背景 . . . . .                   | 3  |
| 1.2   | 既往研究 . . . . .                   | 3  |
| 1.3   | 研究目的 . . . . .                   | 4  |
| 1.4   | 本論文の構成 . . . . .                 | 4  |
| 第 2 章 | HIV 数理モデルとそのメカニズム                | 6  |
| 2.1   | はじめに . . . . .                   | 7  |
| 2.2   | HIV 数理モデル . . . . .              | 7  |
| 2.3   | HIV 複製メカニズム . . . . .            | 9  |
| 2.4   | むすび . . . . .                    | 10 |
| 第 3 章 | 制御手法                             | 11 |
| 3.1   | 強化学習 . . . . .                   | 12 |
| 3.2   | Q-learning . . . . .             | 14 |
| 3.3   | Deep Q-learning . . . . .        | 16 |
| 3.3.1 | Fixed Target Q-Network . . . . . | 17 |
| 3.3.2 | Experience Replay . . . . .      | 19 |
| 3.3.3 | Reward Clipping . . . . .        | 20 |
| 3.4   | オフライン強化学習 . . . . .              | 20 |
| 3.5   | DQN を用いたオンライン強化学習 . . . . .      | 21 |
| 3.6   | むすび . . . . .                    | 22 |
| 第 4 章 | Q-learning を用いた投薬スケジュール          | 23 |
| 4.1   | はじめに . . . . .                   | 24 |

---

|              |                                              |           |
|--------------|----------------------------------------------|-----------|
| 4.2          | Q-learning アルゴリズム . . . . .                  | 24        |
| 4.3          | 数値シミュレーション準備 . . . . .                       | 25        |
| 4.3.1        | 状態・行動・報酬・方策の定義 . . . . .                     | 25        |
| 4.3.2        | 数値シミュレーション条件 . . . . .                       | 27        |
| 4.3.3        | パラメータの定義 . . . . .                           | 28        |
| 4.4          | 数値シミュレーション結果 . . . . .                       | 28        |
| 4.4.1        | 初期値が既知の場合 . . . . .                          | 29        |
| 4.4.2        | 不確実な初期値の場合 . . . . .                         | 30        |
| 4.4.3        | 不確実な初期値 + 白色外乱の場合 . . . . .                  | 32        |
| 4.5          | 数値シミュレーション結果の検討 . . . . .                    | 33        |
| 4.6          | むすび . . . . .                                | 34        |
| <b>第 5 章</b> | <b>オフライン・オンライン強化学習の融合による投薬スケジュールの提案</b>      | <b>35</b> |
| 5.1          | はじめに . . . . .                               | 36        |
| 5.2          | Deep Q-Network の設計 . . . . .                 | 36        |
| 5.3          | オフライン強化学習の設計 . . . . .                       | 38        |
| 5.4          | オンライン強化学習の設計 . . . . .                       | 40        |
| 5.5          | オフライン・オンライン強化学習の融合システムの設計 . . . . .          | 41        |
| 5.6          | シミュレーション設定 . . . . .                         | 42        |
| 5.7          | シミュレーション計算 . . . . .                         | 43        |
| 5.7.1        | Q-learning . . . . .                         | 43        |
| 5.7.2        | Deep Q-learning . . . . .                    | 44        |
| 5.7.3        | Deep Q-learning (Replay Memory なし) . . . . . | 46        |
| 5.7.4        | 種類を考慮した投薬スケジュール . . . . .                    | 47        |
| 5.8          | 考察 . . . . .                                 | 49        |
| 5.8.1        | オンライン強化学習による投薬スケジュール . . . . .               | 49        |
| 5.8.2        | オフライン強化学習による投薬スケジュール . . . . .               | 51        |
| 5.9          | 課題点 . . . . .                                | 51        |
| 5.10         | むすび . . . . .                                | 52        |
| <b>第 6 章</b> | <b>結論</b>                                    | <b>53</b> |
| 6.1          | 結論 . . . . .                                 | 54        |
| 6.2          | 今後の課題 . . . . .                              | 54        |

---

|      |    |
|------|----|
| 目次   | ii |
| 参考文献 | 56 |
| 謝辞   | 59 |

---

# 動的個別化治療に向けたオフライン・オンライン強化学習の融合による

## HIV 投薬スケジュールの最適化

62121454 渡辺 功侑, 指導教員 大森 浩充 教授

### 1. 序論

HIV ウイルス量のコントロールにはART(多剤併用療法)が主流な治療法であり, HIV ウイルス量にかかわらず早期治療が進められている[1]. 一方で,ART においては推奨される組み合わせが少なく, 個人に適合した治療を選択することができない結果, 治療が失敗してしまうケースも少なくない. 本研究では, 強化学習手法の一つであるDQNを用いたオンライン強化学習とオフライン強化学習融合システムの採用により, 特定の時間や状態に合わせた投薬の種類と量を導く.

### 2. HIV 数理モデル

HIV 長期複製過程を考慮した数理モデル[2]を以下に示す.

$$\begin{aligned}\frac{dX}{dt} &= \frac{\lambda}{1+V(t)} - \mu_x X(t) + rX(t) \left(1 - \frac{X+Y+Z}{P_{max}}\right) - k_1 XV, \\ \frac{dY}{dt} &= k_1 X(t)V(t) - \mu_y Y(t) - k_2 Y(t), \\ \frac{dZ}{dt} &= k_2 Y(t) - \mu_z Z(t), \\ \frac{dV}{dt} &= (1-u(t))N\mu_z Z(t) - k_1 X(t)V(t) - \mu_v V(t).\end{aligned}$$

### 3. シミュレーション

従来手法[3]である Q-learning と提案手法を比較するために,140 日間200 人における報酬の比較を行った. 提案手法のシステムを図 1 に示す. 図 2 には従来手法の, 図 3 には提案手法の報酬の推移を示す.




図 1 オフライン・オンライン融合システムの概要




図 2 報酬の時系列変化(Q-learning)




図 3 報酬の時系列変化(提案手法)

Q-learning と提案手法を比較すると, より最適な行動をとることが可能になり, 報酬が増加することが確かめられた. 図 4 には投薬の種類と量を考慮した投薬スケジュールを示す.




図 4 提案された投薬スケジュール

### 4. 結論

DQN とオフライン・オンライン強化学習の採用により, 長期的な報酬の上昇や, 投薬の種類を提案することを示した.

### 参考文献

- [1]. Strategies for Management of Antiretroviral Therapy (SMART) Study Group, El-Sadr WM, et al, CD4+ count-guided interruption of antiretroviral treatment. N Engl J Med 355(22), 2006, 2283-96
- [2]. Perelson A, Kirschner D, DeBoer R: The dynamics of HIV infection of CD4 T-cells. 1993, Math Biosci p114-25
- [3]. Hossein Gholizade-Narm1, Amin Noori, Control the population of free viruses in nonlinear uncertain HIV system using Q-learning. International journal of machine learning and cybernetics, 07, Vol.9 (7),2018, p1169-79

# 第 1 章

## 序論

## 1.1 研究背景

医療技術の発展により、様々な薬剤が登場し従来は治療することが不可能な病気に対して治療することが可能になった。そのような病気の一つとして、AIDS(後天性免疫不全症候群)が挙げられる。AIDS の感染源である HIV ウイルスはレトロウイルスといい、RNA を DNA に転写させる逆転写酵素を使用し、一度感染すると感染個体は感染源となる。HIV 感染症にかかる、感染後 2 ～ 9 週間後に伝染性単核球症を発症し、HIV 抗原が血中に検出される。その後 8～9 年間でリンパ節腫大や AIDS Related Complex の時期を経て AIDS を発症する [1]。

AIDS 発症予防のための主流な治療法は ART(多剤併用療法)であり、ART のレジメンには、逆転写酵素阻害剤 (RTI) とプロテアーゼ阻害剤 (PI) という少なくとも 2 種類の薬剤が含まれる。逆転写酵素阻害剤 (RTI) は、ウイルスの RNA ゲノムを DNA に変換して、宿主細胞の DNA に統合する逆転写酵素の作用を阻害することにより、感染率を低下させる。その一方で、プロテアーゼ阻害剤 (PI) は感染した宿主細胞から放出されるウイルス粒子の量を減少させる [2]。ART により不治の病といわれていた HIV 感染症は、HIV 感染を管理可能なレベルに維持することができる一方、ART は長期使用による副作用を有することも懸念されている [3]。また ART においては推奨される組み合わせが少なく、個人に適合した治療を選択することができない結果、治療が失敗してしまうケースも少なくないのが現状である。

## 1.2 既往研究

HIV ウイルスの増殖・複製過程をダイナミクスとして表現すべく、多くの研究で HIV 数理モデルが明らかになってきた。実際、細胞とウイルス間の相互作用がモデル化されることで、最適な投薬量をあらゆる手法で求める研究が進んできた。しかし、HIV 数理モデルにおいては完全な分析は困難である。これは、非線形モデルにおけるパラメータは実際には未知の値であるためにシミュレーションの結果は不完全となってしまうからである [4–6]。したがって、あらゆる非線形微分方程式で表現される数理モデルには、病気のプロセスにおける確率項が含まれ、多くの研究者はこの HIV 決定論的モデルに基づき、HIV 感染者に最適な薬物スケジュールの研究を行ってきた。

Orellena [7] は免疫反応と多剤効果を含む常微分方程式により表現されたモデルを用いた、最適制御問題に帰着させることで、最適投薬スケジュールを提案した。Agusto [8] らは HIV 患者のうち 7 ～ 10% 程度が感染する結核と AIDS の同時感染についての決定論

---

的モデルと、最適制御理論をもちいて、病気のまん延を制御する戦略を提示した。

また、医療分野では制御手法として最適制御以外にも強化学習を用いて、複雑な問題を解決するうえで大きな成果を上げてきた。Ernst [9] らは初めて HIV 感染者のために構造化治療中断 (STI) 戦略における計算に強化学習手法を用いた。従来は正確な HIV 数理モデルが必要であったが、オフライン方式の、バッチ RL 法を使用しているため、臨床データをもとにして最適な薬物処方戦略を導くことができた。Parbhoo [10] はランダム化されたツリーを用いて、適合 Q 反復 (FQI)、ニューラル FQI、最小二乗政策反復 (LSPI) という 3 種類のバッチ RL 法を薬物スケジュールに適用した。また南アフリカの Charlotte Maxeke Johannesburg Academic Hospital における 250 人の HIV 臨床データを使用した試験では、臨床医が提示した治療法と同等の治療法を提案することが示された。

Hosseini [11] らの研究では、HIV モデルに対して強化学習の一つである Q-learning を用いて最適な薬物スケジュールを提案している。また胸腺の不確実性を表すために、不確実な初期条件や白色外乱を印加した場合でも、HIV 遊離ウイルス量をコントロールするという成果を挙げた。

強化学習の問題点として、オンライン強化学習で得られた戦略はニューラルネットワークの重みに過ぎないため、学習過程が安定しないために人命にかかわる実際の医療現場での適用が困難であることが挙げられる [12]。

### 1.3 研究目的

本研究の目的は、HIV 数理モデルに対して、強化学習の一つである Deep Q-learning を用いたオンライン強化学習と、実際の患者の臨床データに基づくオフライン強化学習を組み合わせることで、学習過程も安定させた投薬スケジュールを提案することである。また、先行研究 [11] では最適な投薬量のみを導いていたが、臨床試験データを用いて最適な投薬量と投薬の種類を求めることを目指す。

### 1.4 本論文の構成

本論文は次のように構成されている。2 章では本論文で使用する HIV 数理モデルについて示し、3 章では強化学習の基本概念と、その手法の一つである Deep Q-learning を紹介する。4 章では、先行研究における Q-learning を使用した投薬スケジュールについて説明し、5 章では、Deep Q-learning [13] を用いたオフライン・オンライン強化学習のシミュレーション結果を示し、分析する。また、Replay memory をなくした場合についての結果

---



との比較も行う。最後の章では結論と今後の課題を述べる。

## 第 2 章

# HIV 数理モデルとそのメカニズム

## 2.1 はじめに

本章では, 本論文において使用する HIV 数理モデルおよび, HIV 感染メカニズムや投薬の効果について説明する. 現在に至るまで HIV ウイルスと免疫系の相互作用を表現する数理モデルに関して, 多くの研究が行われてきた [6] [14] 本論文において使用する数理モデルは Perelson [15] [16] によって提案されたものであり, このモデルの特徴は HIV ウイルスの複製前期過程と後期過程を 4 つという少ない状態数で表現しているところである. ここで, ウイルス複製前期過程と後期過程についての説明を行う.

HIV 病原体が感染の際に受容体分子と結合し, ウイルスの外側の脂質二重層であるウイルスエンベロープは細胞膜と融合する. 次にウイルス粒子内のキャプシドが遊離し, その中のウイルス RNA が細胞質へ露出する. そして RNA に結合している逆転写酵素によりウイルス DNA への変換が起きる. その後合成されたウイルス DNA が細胞核内に移行し, ウイルスが持ち込んだインテグレースにより DNA の染色体への組み込みが行われる. こままでの過程をウイルス複製前期過程という.

次に, 細胞性転写機構によりウイルス DNA から転写が起き, mRNA が合成され, その RNA が細胞質へ移動し翻訳が起きる. そして, 合成されたキャプシドタンパクと逆転写やインテグレースなど酵素がそれぞれ集積会合し, 細胞外へウイルスとして出芽する. これにより出芽したウイルスは完全なウイルス粒子として成熟する. このように転写から成熟までの過程をウイルス複製後期過程という [17] ウイルス複製後期過程を考慮するモデルを使用することにより, 短期的ではなく, 長期的なウイルスと免疫の相互作用を考慮した投薬スケジュールを組むことができる.

## 2.2 HIV 数理モデル

Perelson [15] [16] により提案された HIV 複製数理モデルを式 (2.1)-(2.4) に示す. ただし, 本数理モデルにおいて,  $X$  は未感染 CD4-T 細胞数,  $Y$  は潜伏感染 CD4-T 細胞数,  $Z$  は活動感染 CD4-T 細胞数,  $V$  は遊離ウイルス量を表す. 未感染 CD4-T 細胞  $X$  はウイルスの影響を受けていない, 健康な CD4-T 細胞である. 潜伏感染 CD4-T 細胞  $Y$  はウイルス複製の前期過程において, ウイルスが細胞に侵入した後の細胞であり, それ自体はウイルスとならないが, 時間の経過とともに活動感染細胞を生じるものである. 活動感染細胞  $Z$  は, それ自体はウイルスではないが時間の経過により遊離ウイルスを生み出してしまい, ウイルス複製後期課程の細胞である. そして活動感染細胞  $Z$  によって作成された遊離ウイ

---

ルスは感染源であり, 細胞外に放出されると他の細胞に侵入し, ウイルスを複製する.

$$\frac{dX}{dt} = \frac{\lambda}{1+V(t)} - \mu_x X(t) + rX(t)\left(1 - \frac{X+Y+Z}{P_{max}}\right) - k_1 X(t)V(t) \quad (2.1)$$

$$\frac{dY}{dt} = k_1 X(t)V(t) - \mu_y Y(t) - k_2 Y(t) \quad (2.2)$$

$$\frac{dZ}{dt} = k_2 Y(t) - \mu_z Z(t) \quad (2.3)$$

$$\frac{dV}{dt} = (1-u(t))N\mu_z Z(t) - k_1 X(t)V(t) - \mu_v V(t) \quad (2.4)$$

制御入力  $u$  は式 (2.4) における  $u(t)$  であり,  $[0,1]$  の範囲での投薬量を示している. すなわち,  $u$  が 0 に近いほど無投薬に近く, 反対に 1 に近いほど完全な投薬に近いということを表している. 式 (2.1)~(2.4) で使用されているパラメータを表 2.1 に示す. ここで, 式 (2.1) における  $\frac{\lambda}{1+V(t)}$  は CD4-T 細胞の生成数を表し, 遊離ウイルス量  $V$  が増加すると, そのぶん生成数は減少する. また, 変数  $X \sim V$  には死亡率が  $\mu_x \sim \mu_v$  として定義されている. さらに  $P_{max}$  は CD4-T 細胞の最大値であり,  $X \sim Z$  の CD4-T 細胞の合計はこの値を超えてはならない.

表 2.1: 数理モデル [15] [16] に使用されているパラメータ

| パラメータの名称  | パラメータの説明                        |
|-----------|---------------------------------|
| $\lambda$ | 新たな CD4-T 細胞の生成率                |
| $R$       | CD4-T 細胞の成長率                    |
| $N$       | 活動感染細胞 $Z$ によって生成される遊離ウイルス数     |
| $k_1$     | 遊離ウイルスにより CD4-T 細胞が感染する割合       |
| $k_2$     | 潜伏感染細胞 $Y$ から活動感染細胞 $Z$ に変換する割合 |
| $\mu_x$   | 未感染 CD4-T 細胞 $X$ の死亡率           |
| $\mu_y$   | 潜伏感染 CD4-T 細胞 $Y$ の死亡率          |
| $\mu_z$   | 活動感染 CD4-T 細胞 $Z$ の死亡率          |
| $\mu_v$   | 遊離ウイルス $V$ の死亡率                 |
| $P_{max}$ | CD4-T 細胞の最大値                    |

## 2.3 HIV 複製メカニズム

HIV 数理モデルにおける  $X \sim V$  と投薬量  $u$  の相互関係を図 2.1 に示す. また, HIV 感染メカニズムは次の通りである. 未感染 CD4-T 細胞  $X$  に遊離ウイルス  $V$  が侵入すると,  $k_1 V(t)X(t)$  が感染し, 潜伏感染細胞  $Y$  へと変化する. 次に, 時間の経過とともに潜伏感染細胞  $Y$  のうち  $k_2 Y(t)$  が活動感染細胞  $Z$  へと変化する. 活動感染細胞  $Z$  は抗体免疫反応により刺激を受けると, 死亡するとともに誤って遊離ウイルス  $V$  を複製してしまう. 投薬量  $u(t)$  が作用する段階は, 活動感染細胞  $Z$  が遊離ウイルス  $V$  へと変化する際であり, 投薬の効果により遊離ウイルスへと変化する活動感染細胞  $Z$  は  $u(t)N\mu_z Z(t)$  だけ減少する. 投薬の効果を受けなかった活動感染細胞は遊離ウイルスへと変化する, 細胞外へ放出される. そして新たな細胞で同様の複製を繰り返す. また本研究においては数理モデルの 4 つの状態変数  $X, Y, Z, V$  のうち  $X, V$  を可観測であると仮定した.




図 2.1: HIV 感染メカニズムと投薬の効果

ART(多剤併用療法) が初めて登場したのは 1990 年代であり, 当時は HIV ウイルスに関する研究が進んでいなかったために, 体内から完全にウイルスを排除する目的で ART 治療が使用されていた. 後の研究で HIV ウイルスは図 2.1 のような感染モデルを持っており, 仮に遊離ウイルスをなくすことができたとしても, 細胞内に潜伏している潜伏感染細胞が時間の経過とともに活動感染細胞を生み出し, 結果として遊離ウイルスを生じてしまうことが判明したため, 2011 年ごろまでは血中 CD4 細胞数が  $200 \sim 350/\mu\text{L}$  になるまで治療開始を待つ戦略へとシフトすることとなった. 2012 年以降は ART 治療がウイルス複製前期・後期過程にかかわらず効果があることが証明され, 治療開始時期の目安を血中のウイルス量にかかわらず行うように変化した [18]

## 2.4 むすび

本章では使用する HIV 複製数理モデルの定義, 4 つの状態変数の定義, HIV ウイルスが複製されるメカニズムについて示した. また, HIV ウイルスの複製過程においての投薬が及ぼす影響についても示した.

## 第 3 章

### 制御手法

### 3.1 強化学習

本章では, 制御手法である強化学習についての概念の説明から基本的な導入を行う. 強化学習 (Reinforcement Learning(RL)) とは, 環境 (Environment) とエージェント (Agent) の相互作用において特定のタスクを達成するための最適な方法を学習することを目標としている [19] 強化学習においては 3 つの 状態 (state), 行動 (action), 報酬 (reward) が重要である. また, それら 3 つの概念は環境 (Environment) とエージェント (Agent) の相互作用のなかで循環している. 環境とは制御対象であり, それ自体を変化させることはできない. エージェント (Agent) とは制御器であり, 環境を制御するために最適なルールの作成や指令を行う. このような環境 (Environment) とエージェント (Agent) の相互作用の関係を図 3.1 に示す. ただし, 赤字部分は本研究における環境 (Environment), エージェント (Agent), 行動 (action) である.



図 3.1: 環境とエージェントの相互作用

本研究において, エージェント (Agent) は HIV モデルに対して action(投薬量) を作用させ, 投薬量が短期的にどれほどの価値をもっているかという指標である報酬 (reward) と次の状態 (state) を得る. そして得られた状態 (state) をもとに薬物管理者は最適な行動 (action) を選択する. これを繰り返すことにより, 環境 (Environment) とエージェント (Agent) の相互作用のなかで, 最適な行動 (action) を得られるような方策  $\pi$  を学習することができる.

強化学習における教師信号を表しているものは, 特定の action の短期的な価値を表す reward であるが, 重要なのは短期的な価値が高いことだけが強化学習における目的ではな



いということである。実際には、短期的な価値である reward の期待値で定義される価値関数が最大となるような action をとることが、強化学習における目的である。このような、価値関数を考慮することによって、あらゆるタスクにおいて長期的な価値を重視することが可能になる。価値関数  $V$  は次の式 (3.1) で定義される [11] ただし  $t$  はある時刻を、 $s$  はある状態を表している。

$$V(s) = E\left\{\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s\right\} \quad (3.1)$$

式 (3.1) について、 $\gamma$  は割引率を表し、将来の reward をどれほど割り引くかという指標である。したがって、 $\gamma$  が 1 に近いほど、現在の reward を重視し、0 に近いほど将来の報酬を重視することになる。また、価値関数よりも一般的に使用される関数が、ある state において action をとったときに見込まれる reward の期待値である行動価値関数  $Q(s, a)$  である。行動価値関数  $Q(s, a)$  は式 (3.2) のように与えられる。ただし  $a$  はある行動 (action) を表しているものとする。

$$Q(s, a) = E\left\{\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a\right\} \quad (3.2)$$

エージェント (Agent) は図 3.1 のようにして最適な行動 (action) の決め方のルールである方策  $\pi$  を学習する。ここで、次式のように最適方策  $\pi^*(s)$  を定義する。ただし  $\Pi$  は実現可能なすべての方策  $\pi$  の集合であり、 $V^\pi$  とはある方策  $\pi$  のもとでの価値関数  $V(s)$  を示している。すなわち最適方策とはすべての方策の集合のうち、最も価値関数が大きい値をとるときの方策を表している。

$$\pi^*(s) = \operatorname{argmax}_{\pi \in \Pi} V^\pi(s) \quad (3.3)$$

最適方策  $\pi^*$  を式 (3.3) のように定義するとき、最適方策  $\pi^*$  のもとでの価値関数  $V^*$  を次式のように定義する。ただし、 $P_{ss'}^a(s_k = s, a_k = a, s_{k+1} = s')$  は状態遷移確率であり、 $\mathbb{S}$  は状態の集合、 $\mathbb{A}$  は行動の集合、報酬関数  $R_{ss'}^a$  は  $s$ ,  $a$ ,  $s'$  のみに依存し、即時報酬  $r$  を決める関数であると定義する [20]

$$V^* = \max_{a \in \mathbb{A}} \sum_{s' \in \mathbb{S}} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')], s \in \mathbb{S} \quad (3.4)$$

式 (3.4) は最適ベルマン方程式であり、唯一解をもつことで知られている。式 (3.4) を解くことで導かれる価値関数  $Q^*(s, a)$  は次の式 (3.5)(3.6) で定義される。また最適行動価値

関数  $Q^*(s, a)$  は、与えられた状態  $s$  に対する行動  $a$  の良さを評価する指標である。

$$\pi^*(s) = \operatorname{argmax}_{\pi \in \Pi} Q^*(s, a) \quad (3.5)$$

$$Q^*(s, a) = \sum_{s' \in \mathbb{S}} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')] \quad (3.6)$$

## 3.2 Q-learning

Q-learning とは強化学習の中でも、方策  $\pi^*$  を直接関数として定義するのではなく、行動価値関数  $Q^*(s, a)$  を更新することで最適方策を導くオフポリシー学習に分類される。Q-learning においては、状態・行動空間を分割し、特定の状態・行動における行動価値関数  $Q(s, a)$  を Q-Table という表に格納する。状態数  $n \in \mathbb{N}$ 、行動数  $k \in \mathbb{N}$  における Q-Table を図 3.2 に示す。一般的には、Q-Table 中の  $Q$  値を任意の値に初期化したのち、ステップ数が上昇するにつれて Q-Table を更新することで特定の状態において、どの行動をとるべきかを  $Q$  値の大小で判断することができる。

|       |         | action   |          |     |            |          |
|-------|---------|----------|----------|-----|------------|----------|
| state |         | Action 1 | Action 2 | ... | Action k-1 | Action k |
|       | State 1 | $Q_{11}$ | $Q_{12}$ | ... | $Q_{1k-1}$ | $Q_{1k}$ |
|       | State 2 | $Q_{21}$ | $Q_{22}$ | ... | $Q_{2k-1}$ | $Q_{2k}$ |
|       | ...     | ...      | ...      | ... | ...        | ...      |
|       | State n | $Q_{n1}$ | $Q_{n2}$ | ... | $Q_{nk-1}$ | $Q_{nk}$ |

図 3.2: Q-Table の一例

Q-learning において毎ステップごとに、エージェント (Agent) は報酬 (reward) と状態 (state) を受け取り、 $Q(s, a)$  を更新する。 $Q$  値の更新式は次式で定義される。

$$Q^*(s_t, a_t) = Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \max_{a \in A} Q(s_{t+1}, a) - Q(s_t, a_t)] \quad (3.7)$$

ただし、 $\alpha$  は学習率であり、エージェント (Agent) が一度の学習でどれほど  $Q$  値を更新するかという度合いを表している。つまり、学習率  $\alpha$  が 0 に近いほど学習における  $Q$  値の更新のレベルが低く、一方で  $\alpha$  が 1 に近いほど一度の更新を重視するということになる。

行動選択の際、エージェント (Agent) が行動を選択する際に、はじめから  $Q$  値が最大となる行動をとり続けてしまうと、学習が不完全な場合に誤った行動を選択してしまうこと

で、行動の偏りが生じてしまう。結果として、より良い行動が存在するにも関わらず、その行動を見逃してしまうことになり兼ねない。そのような行動の偏りを防ぐために、行動の選択には  $\epsilon$ -greedy 法や softmax 法が採用される。

$\epsilon$ -greedy 法とは、 $0 \leq \epsilon \leq 1$  によって定義されるパラメータ  $\epsilon$  以下の確率でランダムな行動をとり、学習が進むにつれて、 $\epsilon$  の値を小さくすることで活用と探索のバランスをとるという手法である。一般的には指数的に減少させることで、はじめはランダム性を持った探索をメインに行い、学習が進む過程で急激に現在持っている情報の活用へと切り替える手法が用いられている。

一方で、softmax 法とは確率  $p(a) = \frac{e^{\frac{Q(s_t, a_t)}{T}}}{\sum_{k=1}^n e^{\frac{Q(s_t, a_k)}{T}}}$  で行動を選択する手法である。確率  $p(a)$  に含まれる  $T$  は計算温度であり、このパラメータを調整することで  $Q$  値の大きい行動を際立たせたり、均一化させたりすることが可能になる。そこで図 3.3 には softmax 関数の計算温度  $T$  を 5 段階に変化させたときの得られる出力の違いを示す。ただし横軸は  $Q$  値の値であり  $[0, 1]$  で 10 段階の値をもち、縦軸は softmax 関数によって選択される確率  $p(a)$  を表している。




図 3.3: softmax 関数の計算温度  $T$  による出力の違い

図 3.3 から、計算温度  $T$  が 0.1 のとき、 $Q$  値が 1 を選択する確率が際立つ一方で、1 以下の値は選択される確率が大きく減少していることがわかる (活用)。その一方で  $T$  が 5 あるいは 10 のとき、 $Q$  値にかかわらず選択される確率はほとんど均一化されていること

がわかる (探索). このように, 計算温度の値を調整することによって活用と探索の均衡をとることができ,  $T = 1$  のときはそのバランスが取れていることがわかる.

### 3.3 Deep Q-learning

Q-learning では, 図 3.2 のように状態・行動空間における Q 値を格納するが, 状態・行動数が増加すると次元の呪い, つまり状態・行動数を増やすと計算コストが大きくなってしまいが, 逆に状態・行動数を減少させてしまうと精度が低下してしまう現象により実用化が非現実的になってしまうことが懸念されている [21] そこで, 状態・行動空間を増加させた場合でも, Q 値を導くことができる RL 手法を採用する必要がある. そのような手法の一つとして広く使用されている, Deep Q-Network (以下, DQN と称する) を説明する. DQN [13] は Q-learning の改良型アルゴリズムであり, 特定の行動に対して Q 値を非線形近似することで, Q-learning が高次元の状態・行動空間に適していないという課題を解決することができる. 図 3.4 に DQN の模式図を示す.




図 3.4: Deep Q-Network の構造

図 3.4 について, ニューラルネットワーク (NN) の入力層に状態 (state) を入れると, NN 内部で重み計算をして Q 値を出力として得られる. NN には入力層と中間層 (隠れ層), 出力層が含まれ, それぞれの層の node 数を調整したり, 隠れ層の数を増減させたりすることで出力から得られる Q 値の近似性能や計算負荷を調整することができる.

また, NN の学習では損失関数の最適化として定式化される. つまり入力データに対する NN の出力のずれを最小化するようにパラメータを調整することで NN の学習を進める. そして最適化の際には NN 内部のパラメータの勾配を誤差逆伝播法により計算する.

ここで、誤差逆伝播法についての補足を行う。入力変数  $x_1, x_2, x_3$  を用いて出力  $y$  を計算する過程について考える。ただし、 $f, g$  は二つの配列をもつ関数であるとする。

$$z = f(x_1, x_2), y = g(z, x_3) \quad (3.8)$$

誤差逆伝播法において、 $y$  の各入力に対する勾配を求めることが目的であり、いま  $f, g$  の各入力に対する勾配を求めると仮定する。関数  $g$  は変数  $x_3$  を含むため、 $y$  の  $x_3$  に対する勾配は直接求めることができる。 $y$  の  $x_1, x_2$  に対する勾配は連鎖律から次式のように求められる。

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z} \frac{\partial z}{\partial x_1}, \quad \frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z} \frac{\partial z}{\partial x_2} \quad (3.9)$$

ここで今回の関数における計算グラフを図 3.5 に示す。図 3.5 の点線のように、出力変数  $y$  から入力変数に沿って勾配を計算することで、計算効率を上げることができる。このようにして複雑な計算グラフにおいても合流点で勾配を組み合わせることで、誤差逆伝播法を適用することができる [22]




図 3.5: 計算グラフとその勾配 ([22] より引用)

また、一般的に DQN においては学習を安定化させるために、必要に応じて次のような技術が採用されている。

### 3.3.1 Fixed Target Q-Network

Fixed Target Q-Network とは、DQN のエージェント内部にメインネットワークとは別のネットワークであり、メインネットワークと全く同じ構造を持ち、Q 値の予測値を出

力するネットワークである。DQN においては Q-learning における Q 値の更新式 (3.6) を変形し、予測した Q 値と実際の Q 値の誤差関数を最小にすることを目標とする。この時損失関数は式 (3.10) で与えられる。またメインネットワークのパラメータを  $\theta$ 、ターゲットネットワークのパラメータを  $\theta^-$  とすると、ターゲットネットワークにおける損失関数は式 (3.11) で表される [13] ここで  $Q'_\pi(s', a', \theta_i)$  は NN の出力として予測した Q 値である。

$$L_i(\theta_u) = E[(r + \gamma \max_{a \in \mathbb{A}} Q_\pi(s', a', \theta_i) - Q'_\pi(s, a, \theta_i))^2] \quad (3.10)$$

$$L_i(\theta_u) = E[(r + \gamma \max_{a \in \mathbb{A}} Q_\pi(s', a', \theta_i^-) - Q'_\pi(s, a, \theta_i))^2] \quad (3.11)$$

Q-Network の更新を定期的に行うとともに、Target Network の更新も定期的に行うことで測定値との誤差を修正する必要がある。ただし、毎ステップごとに更新をしてしまうと寧ろ精度が低下してしまうため、10 ステップに 1 回など更新のバランスをとることが重要である。ここでメインネットワークおよびターゲットネットワークの構造を図 3.6 に示す。




図 3.6: DQN Agent における network の構成

ターゲットネットワークの更新手法について、メインネットワークでは loss を計算して誤差逆伝播法を使用するが、ターゲットネットワークでは NN にパラメータを代入するだけでよい。

### 3.3.2 Experience Replay

Q-learning においては現在の状態をもとに Q-Table が最も高い行動を選択し、その経験を一切利用することができない。結果として、過去の経験を利用することができないことによる行動の偏りが発生し兼ねない。このような現象を防ぐために採用されたのが Experience Replay である。図 3.7 に Experience Replay の構造を示す。




図 3.7: Experience Replay の仕組み

Experience Replay は state や reward, action などの経験をメモリに追加することで、メモリの最大数に至るまで経験を貯蓄し、ミニバッチ学習としてランダムに活用することができる仕組みである。ミニバッチ学習とは、経験を格納するメモリの中からランダムに選択し、Agent に渡す学習法であり、一度のミニバッチ学習でいくつかの経験を取り出すかという要素をバッチサイズと呼ぶ。バッチサイズには 4 の倍数が使用され、32 や 64 が多く適用される。バッチサイズが大きくなると、取り出す経験が均質化されてしまい、精度が低下してしまう一方で、バッチサイズが小さいと同時に処理することができるデータ数が小さくなり計算コストが大きくなってしまう。

一般的に、メモリに追加すべき要素は [state, action, next state, reward, True or False(step が終了したか否か)] である。ステップ数がバッチサイズを下回る場合は、ミニバッチ学習をすることができないため、モデルの更新は行わない。また、メモリの最大数を上回る経験数が集まると自動的にメモリから経験を捨てるように設定されている。

Experience Replay を活用してバッチ学習し, DNN(Deep Neural Network) をトレーニングすることで, オンライン上で得られたデータの相関による学習の不安定性を克服することに期待される [23]

### 3.3.3 Reward Clipping

強化学習において, 教師信号である報酬の与え方が学習に影響を大きく与える. 報酬の密度や分布にかかわらず安定した学習をするアルゴリズムが必要であり, その手段の一つとして Reward Clipping が挙げられる. Minh [13] らは報酬を  $[-1, 1]$  にクリッピングすることが安定性を達成する手法の一つであることを示した. 具体的には, すべての正の報酬を  $+1$  に, すべての負の報酬を  $-1$  に統一することで急激な報酬の変化を防ぎ, 勾配計算を安定させるという手法である.

Reward Clipping を利用するメリットとしては最適化目標の分散を抑制することでアルゴリズムの発散を予防することである. その一方でデメリットは, 本来報酬は行動の短期的な価値を与える重要な信号であるにもかかわらず, たとえ大きな価値の違いがあったとしても  $[-1, 1]$  という小さい差に収束してしまうことである. 結果として, 報酬の価値が低下してしまう. したがって, Reward Clipping が推奨される状況は, 医療や精密機械のように状態が急激に変化しない分野であり, 単純なルールが決められたゲームには一度の reward の大小が大きく影響しないため, 使用が推奨されることが多い. 本研究においては, 報酬の大きさを小さくしてしまうと, 投薬量の効果を低下させてしまうため Reward Clipping は使用していない.

## 3.4 オフライン強化学習

強化学習では, 環境 (Environment) をゲームのように正確に定義することは困難であることが多いため, 医療分野や精密加工分野などの失敗が許容されない領域において強化学習の利用は進んでいない. そこで, オフライン強化学習という以前に収集されたインタラクションの静的データセットからのみ学習するパラダイムを採用することで, 教育や医療, ロボット工学などの幅広い実世界アプリケーションへの応用に期待ができる [24] 一般的な強化学習では, 環境 (Environment) とエージェント (Agent) を相互的に作用させるが, オフライン強化学習では, 環境と一切作用させずに CSV データベースなどの過去の経験からエージェント (Agent) が最も Q 値の高い行動を選択する. 図 3.8 にはオフライン強化学習の一般的なメカニズムを示す.






図 3.8: オフライン強化学習の構造

図 3.8 について、その仕組みを具体的に説明する。データセットには state や reward, action の組み合わせが入っており、それらをエージェント (Agent) のメモリに格納する。次に任意の state をエージェント内の DQN 入力層へ入れ、最も Q 値が高い行動を選択する。この際、活用と探索のバランスをとるために  $\epsilon$ -greedy 法などを場合によっては適用する。モデルの更新の際にはメモリ内部からバッチ学習を行う。このように、オフライン強化学習では一方的なフィードフォワード制御のような構造を持つことが特徴である。このようにオフライン強化学習の採用により、従来では事前情報なしに行動し、環境からのフィードバック情報をもとに最適な行動を選択してきたが、環境と一切作用させないことでサンプリング効率の上昇に期待することができる。その一方で、データセット外の行動に関する情報が与えられていないため、Q 値の過大評価による学習精度の低下などの問題を解決する必要がある。

### 3.5 DQN を用いたオンライン強化学習

本章では、環境 (Environment) とエージェント (Agent) の相互作用的な強化学習法であるオンライン強化学習のなかでも、DQN を用いた制御手法について説明する。図 3.9 には一般的な DQN を用いたオンライン強化学習の概要を示す。




図 3.9: オンライン強化学習の構造

オンライン強化学習において、エージェント (Agent) は事前情報なしに入力層に入る state をもとにして最も Q 値が高い行動を  $\epsilon$ -greedy 法などを用いて選択する。そこで得られた行動を環境 (Environment) へ作用させて、環境から新たな state と reward を得る。エージェント内部には Replay Memory(3.3.2 章参照) が存在し、環境からフィードバックされた state や reward など以降の行動選択の際にミニバッチ学習として利用される。このようなサイクルの繰り返しによってメモリに経験が蓄積され、学習が安定するというフィードバック制御のようなメカニズムを持っている。

### 3.6 むすび

本章では、制御手法である強化学習についての導入から、Q-learning や Deep Q-learning のメカニズム、学習を安定化させるための方法、そしてオフライン強化学習、オンライン強化学習の構造の説明を行った。オフライン強化学習やオンライン強化学習にはそれぞれ特有のメリット・デメリットが存在しており、単独で活用するには課題点が残ることが問題である。

## 第 4 章

### Q-learning を用いた投薬スケジュール

## 4.1 はじめに

本章では，従来研究 [11] における Q-learning を用いた最適投薬スケジュールの手法について説明する．はじめに従来研究における Q-learning アルゴリズムの説明を行い，次に状態・行動・報酬・方策の定義を行う．そして数値シミュレーションの条件設定，数値シミュレーションの結果に対する検討を行う．

## 4.2 Q-learning アルゴリズム

従来研究 [11] における Q-learning アルゴリズムの説明を行う．図 4.1 には従来研究における Q-learning の仕組みを示す．

- 1- *Setting initial learning conditions which include:*  
*Iteration=1,  $Q(s,a)$ = arbitrarily or using expert knowledge,  $\alpha=0.1$ ,  $\gamma=0.5$ ,  $T=1$*

2- *While Iteration< Max-Iteration*

  - *Observe the Current state vector  $s_t$  (including current uninfected CD4 cells, and free virus)*
  - *Select action  $a_t$  using softmax policy (choosing action  $a$  with probability of  $\frac{e^{\frac{Q_t(a)_T}{\sum_{b=1}^n Q_t(b)_T}}}{\sum_{b=1}^n Q_t(b)_T}$ )*
  - *By applying action  $a_t$  to dynamic model of HIV system, observe the new state  $s_{t+1}$*
  - *Receive immediate reward  $r_{t+1}$*
  - *Update  $Q(s,a)$  using:  $Q(s_t, a_t) = Q(s_t, a_t) + \alpha[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$*
  - *Reduce the “computational temperature” ( $T$ )*
  - *Set  $s_{t+1}$  to  $s_t$*

図 4.1: 使用する Q-learning アルゴリズム ( [11] より引用)

はじめに，初期のステップでは Q-Table の初期化を行う．また，初期条件として学習率  $\alpha$  を 0.1，割引率  $\gamma$  を 0.5，softmax 関数の計算温度  $T$  を 1 に設定する．

以降は，最終ステップに至るまで state を観測し，action を softmax 法をもちいて選択する．次に HIV システムの数理モデルに action を適用し，次の state(new state) を観測する．そして即時報酬を受け取り，Q 値の更新式 (3.6) を用いて更新する．その後，計算温度  $T$  を減少させ，new state を state に置き換える．以降，最終ステップまでこれを繰り返す．

返す.

### 4.3 数値シミュレーション準備

ここでは従来手法の数値シミュレーションに必要な条件の定義を行う. 具体的には, 状態・行動・報酬・方策の定義や, 数値シミュレーションのパラメータの説明を行う.

#### 4.3.1 状態・行動・報酬・方策の定義

ここでは強化学習において不可欠な要素である状態や行動, 報酬, 方策の定義を行う. まずは状態 (state) の定義を説明する. Q-learning において使用する状態は, 未感染 CD4-T 細胞数  $X$  と遊離ウイルス量  $V$  の二次元配列である. ただし, これらの状態変数は Q-learning において連続量として扱うことができない. これは Q-learning の特性上, Q-Table に離散化した状態を格納する必要があるためである. したがって, 表 4.1 には状態変数の離散化方法と状態番号を示す.

医療データによると, 未感染 CD4-T 細胞数  $X$  の範囲は  $600 \sim 3000$  [ $\text{cells mm}^{-3}$ ], 遊離ウイルス量  $V$  の範囲は  $0 \sim 5$  [ $\text{cells mm}^{-3}$ ] である. そこで  $X, V$  をそれぞれ 240 等分および 100 等分した範囲を考え, 状態番号を振り分ける. より計算の精度を上昇させるためには, 間隔を小さくすればよいが, その分計算コストが大きくなるトレードオフの関係にある.

表 4.1: Q-learning における状態番号の定義

| 遊離ウイルス量 (V)         | 未感染 CD4-T 細胞数 (X)  |                    |     |                      |
|---------------------|--------------------|--------------------|-----|----------------------|
|                     | $600 \leq X < 610$ | $610 \leq X < 620$ | ... | $2990 \leq X < 3000$ |
| $0 \leq V < 0.05$   | state1             | state101           | ... | state23901           |
| $0.05 \leq V < 0.1$ | state2             | state102           | ... | state23902           |
| $\vdots$            | $\vdots$           | $\vdots$           |     | $\vdots$             |
| $4.95 \leq V < 5$   | state100           | state200           | ... | state24000           |

次に行動 (action) の定義を行う. 今回使用する action は投薬量であり, 制御入力  $u$  を表している. 具体的には,  $[0, 1]$  を 10 等分した量で定義され, action が 0 であると無投薬, 1 であると最大の投薬量を示している.

次に報酬 (reward) の定義を行う. 今回使用する報酬  $r_t(s, a)$  はある状態  $s$  において, 行

動  $a$  をするとき, 式 (4.1) で定義される. ただし,  $V_{old}$  は一ステップ前の遊離ウイルス量,  $V_{new}$  は現在の遊離ウイルス量,  $dose_{old}$  は一ステップ前の投薬量,  $dose_{new}$  は現在の投薬量と定義する.

$$r_t(s, a) = \log \frac{V_{old}}{V_{new}} - (dose_{new} - dose_{old}) \log dose_{new} \quad (4.1)$$

式 (4.1) について, 第 1 項ではウイルス量の変化を表している. 以前のステップから遊離ウイルスが減少した場合には, 報酬が増加し, その逆も言える. 第 2 項では投薬量の変化を表している. 前のステップから投薬量が増加すると, その分副作用が大きくなり患者へ与える負担が大きくなってしまう. このような副作用の影響を考慮し, 投薬量が増加すると報酬が減少するように定義されている. このようにして, 報酬  $r_t(s, a)$  は遊離ウイルス量を抑制しつつ, 副作用を最小限に抑えることを最大の目的としている.


最後に方策の定義を行う. 行動選択の際には  $\epsilon$ -greedy 法や softmax 法があるが, 今回は softmax 法を採用する. 具体的には, 次式の確率で行動を選択することで活用と探索のバランスをとることができる.

$$p(a) = \frac{e^{\frac{Q(s_t, a_t)}{T}}}{\sum_{k=1}^n e^{\frac{Q(s_t, a_k)}{T}}} \quad (4.2)$$

確率のフィルタリングにおいて重要なパラメータである計算温度  $T$  は 1 と設定した. しかし, 活用と探索をステップ数に応じて変化させるために計算温度  $T$  はステップごとに減少させる必要がある. そこで次式のように減少させた. ただし,  $k=0.01$ ,  $T_0=1.0$ ,  $episode$  はエピソード数 とする.

$$T = T_0 e^{-k \cdot episode} \quad (4.3)$$

また, 各エピソード数における計算温度  $T$  の値は図 4.2 のように推移する.

図 4.2: エピソード数における計算温度  $T$  の変化

#### 4.3.2 数値シミュレーション条件

ここでは、まず数値シミュレーションの条件について説明を行う。はじめに、初期条件が既知の場合、つまり HIV 数理モデル (2.1)～(2.4) における状態変数  $X \sim V$  の初期値  $X_0 \sim V_0$  が既知の場合の数値シミュレーションを行った。次に、個体差を表現するために、初期条件が未知の場合の数値シミュレーションを行った。最後に、CD4-T 細胞が成熟する胸腺の不確実性を表現するために、白色外乱を印加した場合の数値シミュレーションを行った。表 4.2 には、初期条件が既知の場合における初期値を示す。

表 4.2: 初期値の設定

|                               |      |
|-------------------------------|------|
| 未感染 CD4-T 細胞数 $X$ の初期値 $X_0$  | 1000 |
| 潜伏感染 CD4-T 細胞数 $Y$ の初期値 $Y_0$ | 1    |
| 活動感染 CD4-T 細胞数 $Z$ の初期値 $Z_0$ | 0.01 |
| 遊離ウイルス量 $V$ の初期値 $V_0$        | 1    |

また、初期値が未知の場合に関して、未感染 CD4-T 細胞数  $X$  は  $[0,1000]$  から、遊離ウイルス量  $V$  は  $[0.0,5.0]$  からランダムな値を抽出した。白色外乱を印加した場合について、白色外乱は平均 0、標準偏差 1 の正規分布に従う信号であると仮定し、HIV 数理モデルに加えた。このとき、HIV ダイナミクスは式 (4.5) の通りである。ただし、外乱が印加されていない場合のダイナミクスを式 (4.4) とし、ベクトル  $\hat{X}$  は  $[X,Y,Z,V]$  の四次元配列、 $G(t)$  は任意の関数、 $w(t)$  は外乱信号であると定義する。

$$d\hat{X} = F(\hat{X}, t)dt \quad (4.4)$$

$$d\hat{X} = F(\hat{X}, t)dt + G(t)dw(t) \quad (4.5)$$

### 4.3.3 パラメータの定義

次に数値シミュレーションで使用するパラメータの定義とその設定を説明する。表 4.3 には数値シミュレーションに用いたパラメータの種類とその値を示す。以降行う数値シミュレーションにおいて、表 4.3 の値は共通であるとする。また、割引率  $\gamma$  については初期のステップにおいては 0.5、以降のステップでは 0 とする。

表 4.3: 数理モデル [15] [16] におけるパラメータの設定値

| パラメータの名称  | パラメータの説明                        | 設定値                  | 単位                               |
|-----------|---------------------------------|----------------------|----------------------------------|
| $\lambda$ | 新たな CD4-T 細胞の生成率                | 10                   | $\text{day}^{-1} \text{mm}^{-1}$ |
| $R$       | CD4-T 細胞の成長率                    | 0.03                 | $\text{day}^{-1}$                |
| $N$       | 活動感染細胞 $Z$ によって生成される遊離ウイルス数     | 1200                 | -                                |
| $k_1$     | 遊離ウイルスにより CD4-T 細胞が感染する割合       | $2.4 \times 10^{-5}$ | $\text{day}^{-1} \text{mm}^3$    |
| $k_2$     | 潜伏感染細胞 $Y$ から活動感染細胞 $Z$ に変換する割合 | $3.0 \times 10^{-3}$ | $\text{day}^{-1}$                |
| $\mu_x$   | 未感染 CD4-T 細胞 $X$ の死亡率           | 0.02                 | $\text{day}^{-1}$                |
| $\mu_y$   | 潜伏感染 CD4-T 細胞 $Y$ の死亡率          | 0.02                 | $\text{day}^{-1}$                |
| $\mu_z$   | 活動感染細胞 CD4-T 細胞 $Z$ の死亡率        | 0.24                 | $\text{day}^{-1}$                |
| $\mu_v$   | 遊離ウイルス $V$ の死亡率                 | 2.4                  | $\text{day}^{-1}$                |
| $P_{max}$ | CD4-T 細胞の最大値                    | 1500                 | $\text{mm}^{-3}$                 |

## 4.4 数値シミュレーション結果

本セクションでは数値シミュレーションの結果を示し、それらの検討や課題点の追求を行う。はじめに、状態変数の初期値が既知である場合、そして次に初期値が未知の場合、最



後に初期値が未知 + 白色外乱を印加した場合でセクションが 3 つに分かれている。また、本シミュレーションについてはいずれも筆者が先行研究 [11] を参考にして自力で導いたものである。

#### 4.4.1 初期値が既知の場合

まずは、初期値が既知の場合についての結果を示す。図 4.3 には初期値が既知である場合における未感染 CD4-T 細胞数  $X$  の推移を示す。また、比較要素として一切投薬を行わない場合の  $X$  の推移および定量投薬 ( $\text{action}=0.1$ ) の場合の  $X$  の推移も併載した。




図 4.3: 初期値が既知である場合の  $X$  の推移

図 4.3 について、500 日後には無投薬 (点線) の場合や一定投薬の場合は未感染 CD4-T 細胞数が減少し続けている一方で、Q-learning を用いた手法では 300 日周辺で  $X$  の減少が抑制されることがわかる。結果として、未感染 CD4-T 細胞数の減少は初期値の  $1000[\text{cells mm}^{-3}]$  から約  $950[\text{cells mm}^{-3}]$  と 5% 程度の低下に抑えられている。

次に図 4.4 には初期値が既知である場合における遊離ウイルス量  $V$  の推移を示す。こちらも  $X$  と同様に比較要素として一切投薬を行わない場合の  $V$  の推移および定量投薬 ( $\text{action}=0.1$ ) の場合の  $V$  の推移も併載した。


図 4.4: 初期値が既知である場合の  $V$  の推移

図 4.4 について、500 日後には無投薬 (点線) の場合や一定投薬の場合は未感染 CD4-T 細胞数が増加し続ける一方で、Q-learning による投薬では徐々に遊離ウイルス量は低下していることがわかる。図 4.3 と比較すると、遊離ウイルス量の変動は、未感染 CD4-T 細胞と比較して激しいことが読み取れる。また、HIV ウイルスの複製過程を考慮すると、未感染 CD4-T 細胞数が減少から増加に転じ始めたのち、潜伏感染 CD4-T 細胞数が減少し、活動感染 CD4-T 細胞数が減少し、最終的に遊離ウイルス量に影響する。したがって、遊離ウイルス量に強化学習による投薬の効果が表れるには時間を要することが分析される。

#### 4.4.2 不確実な初期値の場合

次に、不確実な初期値を持つ場合における数値シミュレーションの結果を示す。まずは、ランダムな 10 個のサンプルパスにおける未感染 CD4-T 細胞数の変化を図 4.5 に示す。


図 4.5: 不確実な初期値である場合の  $X$  の推移

図 4.5 に関して、一部のサンプルパスを除いて初期値が 1000 を超えているものは 500 日後には 1000 へ収束し、初期値が 1000 を下回っているパスは 1000 に向かい未感染 CD4-T 細胞数が上昇していることがわかる。次に、不確実な初期値を持つ場合における遊離ウイルス量  $V$  の推移を下図に示す。


図 4.6: 不確実な初期値である場合の  $V$  の推移

図 4.6 に関して, 過渡応答のばらつきはあるものの, 500 日後における定常値はほとんどのパスにおいて遊離ウイルス量は 0, つまり目標値に収束していることがわかる.

#### 4.4.3 不確実な初期値 + 白色外乱の場合

最後に, 不確実な初期値をもつ場合に加えて, HIV 数理モデルに白色外乱を印加した場合における 10 個のサンプルパスの結果を示す. ただし, 不確実な初期値を持つ場合の初期値は 4.4.2 章と等しいものであるとする. 図 4.7 には不確実な初期値および白色外乱が印加されている場合における, 未感染 CD4-T 細胞数  $X$  の推移を示す.




図 4.7: 不確実な初期値 + 白色外乱の場合の  $X$  の推移

図 4.7 に関して, 白色外乱が印加されていても未感染 CD4-T 細胞数  $X$  は初期値から増加傾向にあることが読み取れる. 次に, 図 4.8 には不確実な初期値 + 白色外乱印加下における遊離ウイルス量  $V$  の推移を示す.


図 4.8: 不確実な初期値 + 白色外乱の場合の  $V$  の推移

図 4.8 に関して、白色外乱の影響により 10 個のサンプルパスでは初期値から 500 日後にはウイルス量が減少傾向にあることは読み取れるものの、過渡応答が大きく不安定であり、定常値に関しても白色外乱印加前と比較すると目標値から離れていることがわかる。

## 4.5 数値シミュレーション結果の検討

初期値が既知である場合、未感染 CD4-T 細胞数  $X$ 、遊離ウイルス量  $V$  のいずれについても、比較手法である無投薬や定量投薬と比較して、健康な CD4-T 細胞数が上昇し、遊離ウイルス量が減少することが読み取れる。

初期値が未知である場合も、未感染 CD4-T 細胞数  $X$  や遊離ウイルス量  $V$  の定常値は目標値に近づいている一方で、500 日間経過するまでの間は大きく値が変動していることが読み取れた。

さらに初期値が未知 + 白色外乱を印加した場合では、未感染 CD4-T 細胞数は 500 日後には目標値に近づいている一方で、遊離ウイルス量は途中激しい増減を繰り返しながら振動し、500 日後においても目標値には到達していないパスも複数存在していることが読み取れた。

本研究においては、1 日に 1 度行動 (action)、つまり投薬量を変化させることにより 500 日後には健康な CD4-T 細胞数を増加させ、遊離ウイルス量を減少させることに成功したが、実際には 1 日に 1 回投薬量を変化させることは困難である。また、action を 10 段階で調整しているが、同じ薬剤を使用しているという今回の仮定において、実際に投薬量を 10

段階で変化させることは不可能である。さらに, HAART(多剤併用療法) において投薬の種類を一切考慮せずに投薬スケジュールを提案することは非現実的である。そのうえ, 今回使用した状態 (state) は [未感染 CD4-T 細胞数  $X$ , 遊離ウイルス量  $V$ ] という二次元配列であるが, このような低次元状態では  $X$  や  $V$  の比重が過度に大きいため, 精度の低下や個別化治療の実現の困難などの課題点が生じてしまう。

## 4.6 むすび

この章では, 従来研究 [11] における数値シミュレーションの設定や実際の数値シミュレーション結果, その結果の分析を行った。確かに, Q-learning を用いたアプローチにより初期値が既知の場合や未知の場合, 白色外乱を印加した場合において, 定常値は目標値に近づいているパスが存在することが読み取ることができた。

しかし, 多くのサンプルパスは 500 日に至るまで, 未感染 CD4-T 細胞数や遊離ウイルス量が不安定であり, 1 日に 1 度投薬量を調整することが可能にもかかわらず決して最適な投薬スケジュールを提案することができていないのではないかと, というような問題点を残している。また, 実際に本研究の投薬スケジュールを臨床試験で活用するには, action の分割数が多く, 種類も考慮する必要がある, 患者の個体差情報が不足してる, などの課題がある。これらの課題点を解決するための提案手法を後の章で示す。

## 第 5 章

# オフライン・オンライン強化学習の融合による投薬スケジュールの提案

## 5.1 はじめに

4 章では従来研究 [11] における Q-learning アプローチとそのシミュレーション結果の検討を行った。Q-learning を用いることで長期的にみた定常値は目標値に近づく一方で、学習過程の不安定さや状態・行動数が増加すると次元の呪いにより実用化が非現実的になってしまうことが懸念されている [21] また、1 日に 1 回 action を 10 段階で変化させるという要素や、HAART において投与する薬剤の種類を考慮していないという要素が実用的ではないという課題点が見受けられた。

そこで本章では、はじめに Q-learning から Deep Q-learning に拡張することで状態・行動空間を拡張しても Q 値を近似して導くことを可能にする。次に、action の設定をより現実に沿ったものへと変更し、種類を考慮するためにオフライン強化学習を採用する。そして、オンライン強化学習とオフライン強化学習を一度のループ内で併用することで、患者の状態に最適な投薬量や投薬の種類を導く。さらに、Deep Q-learning の Agent のうち学習を安定化させるための工夫である 3.3.2 章で紹介した Experience Replay の寄与を確かめるため、Replay Memory をなくした場合における比較についても行った。

## 5.2 Deep Q-Network の設計

まずはじめに 3.3 章において紹介した Deep Q-Network の本研究における設計について説明する。ここで使用する DQN は今後の章で紹介する提案手法であるオフライン強化学習やオンライン強化学習における Agent に共通して使用する。今回使用する Deep Q-Network の構造を図 5.1 に示す。ただし、入力層の次元数や出力層の次元数はオフライン強化学習を使用するか、オンライン強化学習を使用するかに応じて変化するため、本図には記載していない。






図 5.1: 本研究における Deep Q-Network の構造

DQN においては値が格納されているノード数や中間層の数によって計算精度や計算コストを調整することが可能である。本研究においては、中間層を 2 層に設定し、また、ノードの配置について、全結合層や畳み込み層、再帰型など用途に応じて様々な配置が考えられるが、本研究では画像処理を行わないため全結合層を使用した。入力層から出力層にかけて誤差逆伝播法を使用して重みの計算を行うが、その際に線形的な変換をすると Q 値を正しく近似することが困難である。そこで入出力の非線形変換をするために用いられるのが活性化関数である。活性化関数にも様々な種類があるが、今回はランプ関数で表現される ReLU 関数を使用した。図 5.2 には ReLU 関数の概要を示す。




図 5.2: ReLU 関数の概要

図 5.2 のように, 横軸の値が 0 以下では出力が 0 になり, 横軸が非負の値をとるときは出力が線形に変化するような関数を用いて変換することにより, 入出力には非線形の関係を持たせることが可能になる. そして, 出力の  $Q$  値を高精度に再現することができる.

### 5.3 オフライン強化学習の設計

次に, 提案手法の一つであるオフライン強化学習について説明する. オフライン強化学習の基本的な概念については 3.4 章で解説しているため, ここでは本研究においてオフライン強化学習をどのように活用しているか, 具体的に示す. オフラインデータを活用する主な目的は以下の通りである.

- 実際のデータを活用することで学習を安定化させる
- 患者の個体差を表現する特徴量を状態に追加する

そこで, このような目的を達成するために実際の HAART 治療の臨床試験データを活用した. 本研究で使用した医療データは, Stanford University HIV 薬物耐性データベース内に保管されている臨床試験 [25] データである. 本臨床試験のデータは具体的には表 5.1 のように与えられている. 左から PTID(患者番号), HIV-Subtype(HIV ウイルスの種類), V Load(遊離ウイルス量), CD4 Count(CD4-T 細胞数), Start Date(投薬開始日), Stop Date(投薬終了日), 使用した薬の種類により構成される. PTID は患者一人一人に割り当てられている. HIV-subtype は HIV ウイルスを細かく分類したものであり, 大半の患者が当てはまる HIV-1 タイプでは A から K の種類に分けることができる [26] 投薬の種類には PI(プロテアーゼ阻害剤) や NRTI(逆転写酵素阻害剤), NNRTI(非核酸系逆転写酵素阻害剤), INSTI(インテグラーゼ阻害剤) の 4 つに分類される計 22 種類を候補として使用した.

表 5.1: HIV 臨床試験データ [25] の概要

| PtID   | Subtype | V<br>Load | CD4<br>Count | Start<br>Date | Stop<br>Date | APV | ... | RAL |
|--------|---------|-----------|--------------|---------------|--------------|-----|-----|-----|
| 268298 | C       | 4.9       | 144          | 0             | 40           | 0   | ... | 1   |
| 268298 | C       | 2.6       | 298          | 0             | 40           | 0   | ... | 0   |
| 268298 | C       | 2.6       | 263          | 0             | 40           | 1   | ... | 0   |
| ⋮      | ⋮       | ⋮         | ⋮            | ⋮             | ⋮            | ⋮   |     | ⋮   |
| 268763 | B       | 2.6       | 616          | 172           | 244          | 0   | ... | 1   |

図 5.3 に今回使用するオフライン強化学習の概要を示す。オフライン強化学習では、環境との相互作用がないため、フィードフォワード構造をとる。オフライン強化学習の NN に入力する state には、未感染 CD4-T 細胞数 X, 遊離ウイルス量 V, HIV-subtype, Start Date, Stop Date の五次元配列を使用した。また, action には 5 次元の投薬の種類を使用した。具体的には, 表 5.1 における 22 種類の投薬の種類及び, 無投薬を合わせた 23 個の数字により構成されるリストとして表現した。つまり, 計算コストを考慮し, 同期間あたりの投薬の最大の種類を 5 種類であると仮定したうえで, 無投薬の場合は 0 を, 特定の種類の投薬を行う場合は APV(1) から RAL(22) までの数字をリストに入れることで投薬の種類やその数を表現することが可能になる。以降, offline action と定義する

例えば, オフライン強化学習において, [12,4,2,22,0] のような提案が行われた場合, 12 番目の DDC, 4 番目の NFV, 2 番目の IDV, 22 番目の RAL の 4 種類が使用されているということを表現する。このようにして, オフライン強化学習における DQN の入力層には 5 つのノードが, 出力層には  $23^5$  つのノードが使用されている。




図 5.3: 本研究におけるオフライン強化学習の概要

本来は活用と探索のバランスをとるために行動選択の際,  $\epsilon$ -greedy 法や softmax 法を使

用するのが一般的である。しかし、本研究におけるオフライン強化学習では一次元でない action にランダム性を持たせることが困難であるため、DQN の出力のうち最も高い Q 値を導いた action のリストを提案治療とした。この際、DQN は action のインデックスを指定するときにリストをそのまま扱うことができない。そこで、DQN に五次元配列を読み込む際には一度相互変換することが可能な関数を通じて一次元のインデックスへと変換したのち、最も高い Q 値をもつインデックスを再び五次元配列へと変換した。

しかし、DQN の出力をそのまま活用する場合は DQN の初期化に応じて算出される Q 値が異なってしまい、偶然意図しない action を導いてしまう可能性がある。そこで、Q 値の全体的な値を考慮して、CSV データセットに存在しない action には Q 値のペナルティを課すように設定した。またこのペナルティが大きすぎる場合は活用に大きく偏ってしまうため、活用と探索のバランスをとれるように調整し、疑似的な  $\epsilon$ -greedy 法として適用した。

## 5.4 オンライン強化学習の設計

次に、本研究におけるオンライン強化学習について説明する。DQN を用いたオンライン強化学習についての概要は 3.5 章で述べた。そこで、より具体的な設定やアルゴリズムを示す。図 5.4 には、本研究におけるオンライン強化学習の構成を示す。




図 5.4: 本研究におけるオンライン強化学習の概要

従来研究 [11] では、投薬量を表している action を  $[0,1]$  で 10 等分した量を考えていたが、本研究ではより実践的に  $[0,1]$  を 5 等分した量を online action と定義する。また、online action の意味は投薬の種類を最大 5 種類としたときの、正規化した量を表している。具体的には、online action が 0.6 を示している場合、5 種類のうち 3 種類を使用すべき

であるということを表している。

このようにして定義された online action は環境である HIV 数理モデルを通り, online action の即時報酬 (reward) と次の状態 (state) を Agent が受け取り,  $\epsilon$ -greedy 法を用いて最適な Q 値を算出する。

## 5.5 オフライン・オンライン強化学習の融合システムの設計

ここでは提案手法であるオフライン強化学習とオンライン強化学習の融合したシステムの説明を行う。ここで使用するオフライン強化学習のメカニズムは 5.3 章に, オンライン強化学習のメカニズムは 5.4 章に示されているものと共通である。図 5.5 には提案手法であるオフライン・オンライン強化学習の融合システムの全体図を示す。




図 5.5: オフライン強化学習とオンライン強化学習の融合システムの概要

図 5.5 に関して, オフライン強化学習とオンライン強化学習の融合システムでは, CSV データベースを活用することで学習を安定化させつつ, 投薬量だけではなく投薬の種類を導くことを図る。具体的には, CSV データベースに基づくオフライン強化学習により offline action を導き, オンライン強化学習により環境と作用させることで online action を導く。最終的には final action として offline action のうち何種類を選択する必要があるか抽出する。次に, 環境から得られた state をオフライン・オンライン Agent に作用させ, それぞれの action を導く。これを繰り返すことで学習の誤差を修正していくのが本研

究における提案手法である。細分化すると、オフライン強化学習では 5.3 章で解説したように環境に作用させないため、フィードフォワード制御系を構成している。一方で、オンライン強化学習では 5.4 で解説したように環境とエージェントの相互作用によるフィードバック制御系を構成している。これらを融合することにより、二自由度制御系のようなシステムの構築が本研究における最終的な目標である。

より具体的にアルゴリズムを説明すると、ある状態 (state) を Online Agent と Offline Agent に入力すると、最も Q 値の高い行動 (action) を選択する。オフライン強化学習では行動の選択肢は  $23^5$  通り存在し、オンライン強化学習では  $[0,1]$  を 5 等分した 6 通り存在する。このようにしてオフライン強化学習における行動 (offline action) とオンライン強化学習における行動 (online action) を Agent は導くことができる。次に、最終的な目標である final action を求めるには、offline action により導いた薬剤の種類の中から、online action の割合だけ抽出する。結果として、種類と量を考慮した final action を導くことができる。

## 5.6 シミュレーション設定

シミュレーションにおいては従来手法である Q-learning および提案手法である DQN の報酬を比較する。具体的には、200 人、140 日間の reward の累積や時系列における報酬平均の推移の比較により、長期的に見た action の価値を評価した。また、DQN における学習を安定させるために用いる Experience Replay の効果を把握するために、提案手法と、提案手法から Replay memory をなくした場合での報酬の比較を行った。シミュレーションに必要なパラメータの設定は表 5.2 に示す。

表 5.2: シミュレーション設定

| パラメータ        | Q-learning           | DQN                  | DQN(Replay Memory なし) |
|--------------|----------------------|----------------------|-----------------------|
| X 初期値        | $[0,1000]$ からランダムな整数 | $[0,1000]$ からランダムな整数 | $[0,1000]$ からランダムな整数  |
| V 初期値        | $[0,5]$ のうち 1 次までの小数 | $[0,5]$ のうち 1 次までの小数 | $[0,5]$ のうち 1 次までの小数  |
| 割引率 $\gamma$ | 初期:0.5 以降:0          | 初期:0.5 以降:0          | 初期:0.5 以降:0           |
| 学習率 $\alpha$ | 0.5                  | 0.5                  | 0.5                   |
| 行動選択         | softmax              | $\epsilon$ -greedy   | $\epsilon$ -greedy    |
| 状態数          | 2                    | 5                    | 5                     |
| 報酬           | 初期: 0 以降: 式 (4.1)    | 初期: 0 以降: 式 (4.1)    | 初期: 0 以降: 式 (4.1)     |
| 行動           | $[0,1]$ を 10 等分したもの  | $[0,1]$ を 5 等分したもの   | $[0,1]$ を 5 等分したもの    |
| 行動頻度         | 1 日 1 回              | 7 日に 1 回             | 7 日に 1 回              |

## 5.7 シミュレーション計算

ここでは, 5.6 章で示したシミュレーション設定に基づくシミュレーションの計算結果を示す. 行ったシミュレーションは, 140 日間の報酬 (reward) の累積, つまり長期的な報酬の大きさと, 200 人の報酬 (reward) 平均の時系列推移である. また, 可観測な状態変数である未感染 CD4-T 細胞数  $X$  および遊離ウイルス量  $V$  の推移についても比較を行った. ここで, 報酬や状態変数の推移はオンライン強化学習を, 種類を考慮した投薬スケジュールはオフライン強化学習を利用している.

### 5.7.1 Q-learning

はじめに従来手法である Q-learning を用いた投薬における累積報酬を図 5.6a に, 報酬平均の推移を図 5.6b に示す.




図 5.6: 累積報酬の分布と報酬平均の推移 (Q-learning)

図 5.6a に関して, これは 200 人の累積報酬の分布である. 時系列ではないため変化として捉えることはできないが, いずれの累積報酬も負の値を持つことが確認される. また, 200 人に近づくにつれて累積報酬が上昇しているのは, ステップ数が上昇するにつれて学習が進行しているためであると分析される.

図 5.6b に関して, これは 140 日間における 200 人平均報酬の推移である. 報酬の定義上, 1 ステップ目での報酬平均は 0 であり, その後急激に報酬は低下する. これは, 初期のステップでは遊離ウイルス量の量に対して未感染 CD4-T 細胞数が少なく, 最大の投薬量

を適用してもコントロールすることが困難であるためであると考えられる。日数を重ねるにつれて、上下を繰り返しながら報酬平均は上昇するものの、140 日経過しても負の値をとり続けることが確認される。

次に Q-learning を用いた投薬における未感染 CD4-T 細胞数  $X$  の推移を図 5.7a に、遊離ウイルス量  $V$  の推移を図 5.7b に示す。




図 5.7: 未感染 CD4-T 細胞数  $X$  と遊離ウイルス量  $V$  の推移 (Q-learning)

図 5.7a に関して、これは Q-learning 手法における 140 日間の未感染 CD4-T 細胞数  $X$  の推移であるが、初期値の大きさにかかわらず 10 個のサンプルパスはいずれも初期値から大きく変化していないことが確認できる。つまり、従来手法では 140 日間で未感染 CD4-T 細胞数の増加につなげることができないことを示唆している。

図 5.7b に関して、これは Q-learning 手法における 140 日間の遊離ウイルス量  $V$  の推移であるが、振動を繰り返しながら初期値が 1 を超えているパスに関しては減少に転じていることが確認される。その一方で、いずれのパスに関しても大きく 1 を下回るような挙動を示さないことが見受けられる。

### 5.7.2 Deep Q-learning

次に提案手法である Deep Q-learning を用いた投薬における 140 日間、200 人の累積報酬の分布を図 5.8a に、報酬平均の推移を図 5.8b に示す。






図 5.8: 累積報酬の分布と報酬平均の推移 (DQN)

図 5.8a に関して、初期のステップでは学習が進んでいないため、累積報酬は負の値をとっているが、30 人目以降は振れ幅こそあるものの、正に転じて累積報酬が最大 50 程度まで上昇していることが確認される。

図 5.8b に関して、初期の学習過程では報酬平均が負の値をとっているが、約 40 日目以降は 0.4 程度に落ちつき、以降もその値を維持していることが確認できる。定期的に報酬が低下している原因は、提案手法では 7 日に 1 度しか投薬量である action をコントロールすることができないためである。また、Deep Q-learning を用いた投薬における未感染 CD4-T 細胞数  $X$  の推移を図 5.9a に、遊離ウイルス量  $V$  の推移を図 5.9b に示す。


図 5.9: 未感染 CD4-T 細胞数  $X$  と遊離ウイルス量  $V$  の推移 (DQN)

図 5.9a に関して、初期値が 1000 から離れているパスについては 140 日間で 200 ほど未感染 CD4-T 細胞数が上昇していることが確認できる。また、ほとんどのパスについても  $X$  の値の上昇がみられる。

図 5.9b に関して、上昇と降下を繰り返しながら全体的に遊離ウイルス量  $V$  は目標値である 0 に向かい減少していることが確認できる。その一方で、140 日間では特に遊離ウイルス量の初期値が小さい場合において、振動が激しいことも見受けられる。

### 5.7.3 Deep Q-learning (Replay Memory なし)

次に Deep Q-learning から Replay Memory を除いた手法を用いた投薬における累積報酬を図 5.10a に、報酬平均の推移を図 5.10b に示す。




図 5.10: 累積報酬の分布と報酬平均の推移 (DQN Replay Memory なし)

図 5.10a に関して、30 日までは提案手法である図 5.8a と同様の挙動を示しているが、以降については累積報酬が 0 より大きな値をとることはほとんどなく、0 に収束していることが確認できる。

図 5.10b に関して、全体的な挙動は提案手法である図 5.8b と類似しているが、学習が進む過程で報酬平均が 0 に収束している点で、提案手法とは異なることが確認される。

また、Deep Q-learning から Replay Memory を除いた手法を用いた投薬における未感染 CD4-T 細胞数  $X$  の推移を図 5.11a に、遊離ウイルス量  $V$  の推移を図 5.11b に示す。




図 5.11: 未感染細胞数  $X$  と遊離ウイルス量  $V$  の推移 (DQN Replay Memory なし)

図 5.11a に関して, 未感染 CD4-T 細胞数の変化は提案手法である図 5.9a と大きく変化せず, ほとんどのパスで上昇傾向にあることがわかる.

図 5.11b に関して, 初期値の値にかかわらず 140 日間では遊離ウイルス量が 1 周辺を推移していることが確認できる.

#### 5.7.4 種類を考慮した投薬スケジュール

最後に, 本研究における最終的な目標である, 投薬の種類を考慮した投薬スケジュールの出力結果を示す. 図 5.12 には, 提案手法であるオンライン強化学習とオフライン強化学習を融合したシステムにおける投薬スケジュール (offline action, final action) を示す. ただし, 以降の図 5.12, 5.13 に共通して導かれた投薬スケジュールは 7 日に 1 度変化するものであり, 最大 5 種類の薬剤のラベルにマーカーが付与される. 水色は offline action を表し, 青は online action によりさらに種類を絞った action を表している.




図 5.12: 提案手法による投薬スケジュール

次に比較対象として, 図 5.13 には提案手法から Replay Memory を除いたシステムにおける投薬スケジュール (offline action, final action) を示す.




図 5.13: オフライン強化学習による投薬スケジュール (Replay Memory なし)

## 5.8 考察

ここでは, 5.7 章におけるシミュレーション結果の考察を行う. はじめに, オンライン強化学習による量的な投薬スケジュールの評価を行い, 次にオフライン強化学習による種類を考慮した投薬スケジュールの評価を行う.

### 5.8.1 オンライン強化学習による投薬スケジュール

まずは, オンライン強化学習の評価を行う. 表 5.3 には従来手法である Q-learning および提案手法である DQN, そして DQN から Replay Memory を除いた手法における累積報酬の平均値と報酬平均の値を示す.

表 5.3: 3 つの制御手法による報酬の平均値

| 比較項目 \ 制御手法 | Q-learning | DQN    | DQN(Replay Memory なし) |
|-------------|------------|--------|-----------------------|
| 累積報酬平均      | -48.821    | 22.809 | -6.071                |
| 時系列報酬平均     | -0.349     | 0.163  | -0.043                |

表 5.3 に関して、これは 3 つの制御手法における累積報酬の平均値 (200 人) と報酬平均 (140 日) を表しているが、従来手法である Q-learning は累積報酬の平均値が約-50 と大きく負の値を示している一方で、提案手法である DQN は 20 を超えており、制御手法の違いにより長期的な報酬の改善がみられる。報酬平均においても収束値の違いにより、提案手法は時系列平均値が正の値を示していることがわかる。このようにして従来手法である Q-learning から提案手法へと変化させることで、7 日に 1 度の頻度でしか action を変化させることができないにもかかわらず、長期的な報酬の改善が確認された。このような報酬の改善は主に次の要素に起因すると考えられる。

- DQN では状態・行動空間を離散化する必要がないため、境界部分における状態の違いによる Q 値のずれが解消された
- Replay Memory の活用により、過去の経験を活用することが可能になったことで、学習が安定化した
- 臨床試験データにおける投薬履歴を活用することで、一から action を起こすよりもサンプリング効率が上昇した

次に Replay Memory の寄与に関して、提案手法から Replay Memory をなくした場合は、Q-learning より累積報酬平均や時系列報酬平均が上昇しているものの、Replay Memory がある場合と比較するとより良い action を見つけることができていないことが、図 5.10a, 5.10b から確認できる。このような結果となった要因の一つは、バッチ学習をすることができないと、現在の state から action を選択するしか方法がなく、ある時間に仮により優れた action をみつけることが可能になったとしても、その成功経験は Replay Memory が存在しないため、以降の行動選択には活用されないことである。このように、Replay Memory の活用は、サンプリング効率を上昇させるとともに、過去の成功経験や失敗経験を活用することで、後の行動選択で優れた行動をみつけることにも役立つことが示された。

### 5.8.2 オフライン強化学習による投薬スケジュール

ここではオフライン強化学習の出力である種類を考慮した投薬スケジュールの結果についての考察を行う。図 5.12 に関して、臨床試験 [25] が行われた当時の HIV 治療方針と比較すると、全期間のうち 6 割は当時の治療方針と一致しており、4 割は一部の薬剤を医師の判断で補完する必要がある、そのうち 1.5 割は当時の医療では認められていなかった組み合わせであるが、後の推奨薬として使用されていたものであった [27] 具体的には、臨床試験が行われた 2005 ～ 2007 年の HAART 治療では 2 種類の NRTI (逆転写酵素阻害剤) と、PI(プロテアーゼ阻害剤) または NNRTI(非核酸系逆転写酵素阻害剤) を混合した治療法が主流であった。その一方で、INSTI(インテグラーゼ阻害剤) は登場したばかりであり、当時は初期治療には採用されていなかった。2008 年以降、INSTI をキードラックとして採用した HAART 治療が承認され、現在も使用されている。

本研究においてオフライン強化学習によって提案された治療方針は、医師の判断する際の材料として使用されることを目的としている。そこで医師の経験や、患者の薬物耐性などから必要な薬を補完することで推奨されている投薬スケジュールを提案することのみならず、今まで採用されていなかったが、より良い薬の組み合わせを開拓する支援をする可能性にも期待できる。

その一方で、図 5.11b に関して、これは比較手法である Replay Memory なしの場合における種類を考慮した投薬スケジュールである。提案手法と比較すると提案されている種類が大幅に減少し、action に偏りが生じていることがわかる。このような結果となった要因としては、DQN の更新の際にバッチ学習をすることができず、現在の state で提案した offline action をもとに次の Q 値を決定するために生じた、初回の offline action の過大評価があげられる。このように、オフライン強化学習においても Replay Memory は過去の経験をバッチ学習しつつ、適切に DQN を更新することで、過度な Q 値の偏りを抑制するように作用している。

## 5.9 課題点

5.7 章や 5.8 章では、提案手法であるオフライン・オンライン強化学習の活用により、140 日間における累積報酬や時系列報酬の向上が確認された。また、5.7.4 章では種類と量を考慮した final action の結果を示し、臨床試験当時の治療方針とおおよそ一致している上に、当時は承認されていなかったが、以降承認される治療法を提案することができるこ

とを示した。しかし、依然として次のような課題点が残る。

- 今回使用した臨床試験データ [25] は患者数が 456 と少ないため offline action に偏りが生じてしまう
- 計算コスト上, offline action の最大数を 5 としたが, 本来は種類が多いほど医師の判断材料を広げることができる
- 個別化治療に近づけるためには, 患者の特徴量を増やす必要があるが, 薬物耐性や患者のパラメータが不足している
- HIV 数理モデルのパラメータは固定であると仮定しているが, 実際には変動するため, モデルの変化へのロバスト性の検証が必要である
- 患者の薬物耐性の影響やサンプル数が少ない HIV-subtype をもつ患者に対する治療法の精度の低下の可能性がある

以上のような課題点を克服するために, より多くのサンプル数があり, 患者の特徴量をもつデータを活用することができれば, 偏りが小さく, 患者個人に適合した治療方針を立てることが期待できる。また, 環境を表す HIV 数理モデルのパラメータ変動に対して, 制御器がどの程度影響を抑制することができるかを考慮することで臨床試験への実現可能性につなげることが期待できる。

## 5.10 むすび

本章では, 提案手法におけるオフライン・オンライン強化学習の設計や, シミュレーション結果, 考察を行った。従来手法である Q-learning から DQN へと拡張し, 臨床試験データを併用したオフライン・オンライン強化学習の制御系を採用することで, 長期的な報酬の向上や, 医療現場における医師の判断支援に役立つ可能性を示した。その一方で, 活用する臨床試験データや数理モデルに対する依存度の高さを克服することの重要性を述べた。



## 第 6 章

### 結論

## 6.1 結論

本研究では, DQN を用いた強化学習手法による HIV ウイルスへの投薬スケジュールの優位性や, オフライン強化学習の採用の優位性, そしてオフライン・オンライン強化学習の融合システムの優位性の確認を行った. 従来手法である Q-learning を用いた投薬スケジュールでは, 1 日 1 度, 10 段階の投薬量を調整することが可能であるが, 長期的な報酬を上昇させることは困難であった. 一方で, 提案手法である DQN を用いた投薬スケジュールでは, 7 日に 1 度, 5 段階の投薬量の調整で長期報酬を, 従来手法よりも上昇させることが確認された.

オフライン強化学習の出力に関して, 臨床試験データをもとにしたオフライン強化学習を採用したところ, サンプル効率の上昇や投薬の種類を提案できることが確認された.

また, オフライン強化学習とオンライン強化学習を融合させたシステムの導入により, ある状態の患者に対して動的な投薬の種類やタイミング, そして投薬量を提案することができ, その結果は概ね臨床試験に適したものであることが確認された.

## 6.2 今後の課題

本研究における課題点としては, まずは使用した HIV 数理モデルのパラメータが変動した場合の制御器のロバスト性を確認する必要があることがあげられる. 本研究におけるオンライン強化学習アルゴリズムでは, HIV 複製数理モデルに依存して提案される投薬量が変動するが, 生体システムにおいて数理モデルのパラメータが変動しないことは保証されない. したがって, 数理モデルに大きな影響を与えるキーパラメータが変動した際にも変動前と同等の長期報酬をもたらすことが可能であれば, 実際の臨床試験における有用性にも期待することができる.

また, 本研究において使用した臨床試験データはサンプル数や個体差を表す特徴量が不足していた. そこでより患者数が多い, 汎用性の高いデータを活用することができれば, より精度の高い投薬スケジュールを提案することができることに期待できる. 加えて, ウイルス学的失敗のためにウイルス量の制御が不可能となってしまった場合, 特定の薬剤の使用は控えられている. しかし, 本研究において使用した臨床試験データには治療の失敗に関するデータは含まれていない. そこで, 患者の治療歴を活用することができれば, ある患者に対しては, 特定の薬剤の使用を除外するという治療方針を立てることが可能になる.

さらに, 医師の意思決定を偏りなく支援するためには, オフライン強化学習の出力次元数を 5 から 10 程度まで拡張させ, より多くの薬剤の組み合わせを考慮する必要がある. 提

案された種類が少ない場合, 医師は過去の経験と投薬スケジュールを参考にする際, より相応しい薬剤の組み合わせが本来存在していたにもかかわらず, 見逃してしまう可能性が考えられる. そこで, 可能な限り出力の最大次元数は拡張したほうが誤差の小さな投薬スケジュールを立てることができる.

## 参考文献

- [1] 俊夫服部, 厚小糸, 利夫村上, 修三松下, 洋助前田, 清高月, 昌功加藤. エイズウイルスの感染機構. 化学と生物, Vol. 27, No. 4, pp. 218–227, 1989.
- [2] Kenneth A Freedberg, Elena Losina, Milton C Weinstein, A. David Paltiel, Calvin J Cohen, George R Seage, Donald E Craven, Hong Zhang, April D Kimmel, and Sue J Goldie. The cost effectiveness of combination antiretroviral therapy for hiv disease. *The New England journal of medicine*, Vol. 344, No. 11, pp. 824–831, 2001.
- [3] Data Collection on Adverse Events of Anti-HIV Drugs (DAD) Study Group. Combination antiretroviral therapy and the risk of myocardial infarction. *New England Journal of Medicine*, Vol. 349, No. 21, pp. 1993–2003, 2003.
- [4] B.M. Adams, H.T. Banks, M. Davidian, Hee-Dae Kwon, H.T. Tran, S.N. Wynne, and E.S. Rosenberg. Hiv dynamics: Modeling, data analysis, and optimal treatment protocols. *Journal of computational and applied mathematics*, Vol. 184, No. 1, pp. 10–49, 2005.
- [5] D M Bortz and P W Nelson. Model selection and mixed-effects modeling of hiv infection dynamics. *Bulletin of mathematical biology*, Vol. 68, No. 8, pp. 2005–2025, 2006.
- [6] Alan S. Perelson and Patrick W. Nelson. Mathematical analysis of hiv-1 dynamics in vivo. *SIAM review*, Vol. 41, No. 1, pp. 3–44, 1999.
- [7] Jose Marie Orellana. Optimal drug scheduling for hiv therapy efficiency improvement. *Biomedical Signal Processing and Control*, Vol. 6, No. 4, pp. 379–386, 2011.
- [8] F.B. Augusto and A.I. Adekunle. Optimal control of a two-strain tuberculosis-hiv/aids co-infection model. *BioSystems*, Vol. 119, No. 1, pp. 20–44, 2014.
- [9] D. Ernst, G.-B. Stan, J. Goncalves, and L. Wehenkel. Clinical data based optimal

- sti strategies for hiv: a reinforcement learning approach. In *Proceedings of the 45th IEEE Conference on Decision and Control*, pp. 667–672. IEEE, 2006.
- [10] Sonali Parbhoo. A reinforcement learning design for hiv clinical trials, 2014.
- [11] Hossein Gholizade-Narm and Amin Noori. Control the population of free viruses in nonlinear uncertain hiv system using q-learning. *International journal of machine learning and cybernetics*, Vol. 9, No. 7, pp. 1169–1179, 2018.
- [12] Kento NAGATA and Sachiyo ARAI. Verifiable reinforcement learning framework by incremental estimation of environmental model: Achieving safe ai via understanding acquired policy. *Proceedings of the Annual Conference of JSAI*, pp. 2E6GS805–2E6GS805, 2024.
- [13] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dhharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature (London)*, Vol. 518, No. 7540, pp. 529–533, 2015.
- [14] Dominik Wodarz and Martin A. Nowak. Mathematical models of hiv pathogenesis and treatment. *BioEssays*, Vol. 24, No. 12, pp. 1178–1187, 2002.
- [15] A. S PERELSON. Modeling the interaction of the immune system with hiv. *Lecture notes in biomathematics*, Vol. 83, pp. 350–370, 1989.
- [16] Alan S. Perelson, Denise E. Kirschner, and Rob De Boer. Dynamics of hiv infection of cd4 + t cells. *Mathematical biosciences*, Vol. 114, No. 1, pp. 81–125, 1993.
- [17] 小柳義夫, 渡部匡史. Hiv 増殖機構と抗 hiv 薬の作用機序. *日本臨牀*, Vol. 68, No. 3, pp. 378–381, 2010.
- [18] W. M. El-Sadr, J. D. Lundgren, J. D. Neaton, F. Gordin, D. Abrams, R. C. Arduino, A. Babiker, W. Burman, N. Clumeck, C. J. Cohen, D. Cohn, D. Cooper, J. Darbyshire, S. Emery, G. Fätkenheuer, B. Gazzard, B. Grund, J. Hoy, K. Klingman, M. Losso, N. Markowitz, J. Neuhaus, A. Phillips, and C. Rappoport. Cd4+ count-guided interruption of antiretroviral treatment. *The New England journal of medicine*, Vol. 355, No. 22, pp. 2283–2296, 2006.
- [19] R.S. Sutton and A.G. Barto. Reinforcement learning: An introduction. *IEEE transactions on neural networks*, Vol. 9, No. 5, pp. 1054–1054, 1998.
-

- 
- [20] 潤一郎吉本, 賢治銅谷, 信石井. 強化学習の基礎理論と応用. 計測と制御, Vol. 44, No. 5, pp. 313–318, 2005.
- [21] Miguel Neves, Miguel Vieira, and Pedro Neto. A study on a q-learning algorithm application to a manufacturing assembly problem. *Journal of manufacturing systems*, Vol. 59, pp. 426–440, 2021.
- [22] Seiya TOKUI. Implementing neural networks : Structure of deep learning frameworks and design concept of chainer(jspecial issue;research frontiers in neural network). *Journal of the Japanese Society for Artificial Intelligence*, Vol. 31, No. 2, pp. 216–222, 2016.
- [23] Joohyun Shin, Thomas A. Badgwell, Kuang-Hung Liu, and Jay H. Lee. Reinforcement learning – overview of recent progress and implications for process control. *Computers chemical engineering*, Vol. 127, pp. 282–294, 2019.
- [24] Rafael Figueiredo Prudencio, Marcos R. O. A. Maximo, and Esther Luna Colombini. A survey on offline reinforcement learning: Taxonomy, review, and open problems. *IEEE transaction on neural networks and learning systems*, Vol. 35, No. 8, pp. 10237–10257, 2024.
- [25] Rami Kantor, Laura Smeaton, Saran Vardhanabhuti, Sarah E. Hudelson, Carol L. Wallis, Srikanth Tripathy, Mariza G. Morgado, Shanmugham Saravanan, Pachamuthu Balakrishnan, Marissa Reitsma, Stephen Hart, John W. Mellors, Elias Halvas, Beatriz Grinsztejn, Mina C. Hosseinipour, Johnstone Kumwenda, Alberto La Rosa, Umesh G. Laloo, Javier R. Lama, Mohammed Rassool, Breno R. Santos, Khuanchai Supparatpinyo, James Hakim, Timothy Flanigan, Nagalingeswaran Kumarasamy, Thomas B. Campbell, and Susan H. Eshleman. Pretreatment hiv drug resistance and hiv-1 subtype c are independently associated with virologic failure: Results from the multinational pearls (actg a5175) clinical trial. *Clinical infectious diseases*, Vol. 60, No. 10, pp. 1541–1549, 2015.
- [26] 武部豊. Hiv-1 分類・命名法の新ガイドラインとサブタイプ分類を巡る諸問題. ウィルス, Vol. 50, No. 2, pp. 123–138, 2000.
- [27] 塚田訓久. 治療ガイドラインの変遷と現状. 日本エイズ学会誌 = The journal of AIDS research, Vol. 22, No. 1, pp. 13–18, 2020.
-

# 謝辞

本研究は、筆者が慶應義塾大学理工学部システムデザイン工学科在学中に、本学科大森浩充教授のご指導のもと、大森研究室で行ったものです。多くの方々のお力添えにより本論文が書き上げられましたこと、ここに深く感謝の意を表します。

この間委細にわたりご指導、ご助言賜りました大森浩充教授に謹んで謝意を表します。そして、著者が本研究室に在籍中、研究を共にした研究室の皆様に感謝致します。特に、1年間様々な助言や指導をしてくださった、星野英祐氏、村上朋希氏、内田崇太郎氏、そして同期として意見交換や情報交換を行った米谷昌悟氏、藤本詠士氏、西垣叡氏に心より感謝申し上げます。

最後に、筆者を経済面で支えてくださった家族や精神面で支えてくださった友人全員に感謝いたします。