

動的個別化治療に向けたオフライン・オンライン強化学習の融合による HIV 投薬スケジュールの最適化

渡辺功侑 (慶應義塾大学), 大森浩充 (慶應義塾大学)

Optimizing HIV Treatment Schedules Through a Fusion of Offline and Online Reinforcement Learning for Dynamic Personalized Therapy

* K. Watanabe (Keio University), *H. Ohmori (Keio University)

Abstract— Scientific and technological developments have transformed the HIV virus from an incurable disease to a treatable one. However, HAART (antiretroviral therapy), which is currently the mainstay of treatment, administers only a few fixed drugs and does not provide personalized treatment. In this paper, we propose a dynamic personalized treatment strategy by combining offline and online reinforcement learning using DQN (Deep Q-Network).

Key Words: Deep Q-Network, Reinforcement Learning, Neural Network

1 はじめに

医療技術の発展により、様々な薬剤が登場し従来は治療することが不可能な病気に対して治療することが可能になった。そのような病気の一つとして、AIDS(後天性免疫不全症候群)が挙げられる。

AIDSの感染源であるHIVウイルスはレトロウイルスといい、RNAをDNAに転写させる逆転写酵素を使用し、一度感染すると感染個体は感染源となる。HIV感染症にかかると、感染後 2~9 週間後に伝染性単核球症を発症し、HIV抗原が血中に検出される。その後 8~9 年間でリンパ節腫大やエイズ関連症候群(AIDS Related Complex)の時期を経てAIDSを発症する¹⁾。

HIVウイルスの感染過程には前期過程と後期過程がある。具体的には、ウイルスが細胞に侵入し、DNA染色体への組み込みが行われるまでの過程をウイルス複製前期過程、転写から成熟までの過程をウイルス複製後期過程という²⁾。ART(多剤併用療法)はHIVウイルスの前期・後期過程にかかわらず有効であり、CD4 細胞数にかかわらず早期治療が進められている³⁾。

ART(多剤併用療法)のレジメンには、逆転写酵素阻害剤(RTI)とプロテアーゼ阻害剤(PI)という少なくとも2種類の薬剤が含まれる。RTIは、ウイルスのRNAゲノムをDNAに変換して、宿主細胞のDNAに統合する逆転写酵素の作用を阻害することにより、感染率を低下させる⁴⁾。一方で、PIは感染した宿主細胞から放出されるウイルス粒子の量を減少させる。逆転写酵素阻害剤とプロテアーゼ阻害剤を適切に組み合わせることにより、HIV感染を管理可能なレベルに維持することができる一方、ARTは長期使用による副作用を有することも懸念されている⁵⁾⁶⁾。ART以外の治療法では、カボテグラビル超長時間作用型(CAB-ULA)に関する臨床試験が進んでおり、少なくとも4か月に1回の皮下注射での効果が期待されている⁷⁾。しかし、皮下注射による治療は通院の頻度を短縮する効果がある反面、錠剤治療よりもコストがかかることが懸念されているため、普及するまでは時間を要する。

このようにして、ARTを行うことで長期的な治療によるHIVウイルス量のコントロールが可能になった一方で、ARTにおいては推奨される組み合わせが少なく、個人に適合した治療を選択することができない結果、治療が失敗してしまうケースも少なくない。そこで、

動的な治療を可能にするための最適な投薬スケジュールに関する研究が進められている。

HIVウイルスの増殖・複製過程をダイナミクスとして表現すべく、多くの研究でHIV数理モデルが明らかになってきた。実際、細胞とウイルス間の相互作用がモデル化されることで、最適な投薬量をあらゆる手法で求める研究が進んできた。しかし、HIV数理モデルにおいては完全な分析は困難である。これは、非線形モデルにおけるパラメータは実際には未知の値であるためにシミュレーションの結果は不完全となってしまうからである⁸⁾⁻¹⁰⁾。したがって、あらゆる非線形微分方程式で表現される数理モデルには、病気のプロセスにおける確率項が含まれ、多くの研究者はこのHIV決定論的モデルに基づき、HIV感染者に最適な薬物スケジュールの研究を行ってきた。Orellena¹¹⁾は免疫反応と多剤効果を含む常微分方程式により表現されたモデルを用いた、最適制御問題に帰着させることで、最適投薬スケジュールを提案した。Agusto¹²⁾らはHIV患者のうち7~10%程度が感染する結核とAIDSの同時感染についての決定論的モデルと、最適制御理論をもちいて、病気のまん延を制御する戦略を提示した。

また、医療分野では制御手法として最適制御以外にも強化学習(Reinforcement Learning (RL))¹³⁾を用いて、複雑な問題を解決するうえで大きな成果を上げてきた。Ernst¹⁴⁾らは初めてHIV感染者のために構造化治療中断(STI)戦略における計算に強化学習手法を用いた。従来は正確なHIV数理モデルが必要であったが、オフライン方式の、バッチRL法を使用しているため、臨床データをもとにして最適な薬物処方戦略を導くことができた。Parbhoo¹⁵⁾はランダム化されたツリーを用いて、適合Q反復(FQI)、ニューラルFQI、最小二乗政策反復(LSPI)という3種類のバッチRL法を薬物スケジュールに適用した。また南アフリカのCharlotte Maxeke Johannesburg Academic Hospitalにおける250人のHIV臨床データを使用した試験では、臨床医が提示した治療法と同等の治療法を提案することが示された。Hossein¹⁶⁾らの研究では、HIVモデルに対して強化学習の一つであるQ-learningを用いて最適な薬物スケジュールを提案している。また胸腺の不確実性を表すために、不確実な初期条件や白色外乱を印加した場合でも、HIV遊離ウイルス量をコントロールするという成果を挙げた。医療分野とRLの研究は進む中で、HIVウイルスに対する強化学習の研究は癌などの疾患と比較しても稀有で

ある。また、強化学習の問題点として、オンライン強化学習で得られた戦略はニューラルネットワークの重みに過ぎないため、学習過程が安定しないことが挙げられる¹⁷⁾。さらに、オンライン強化学習の使用においてはサンプリング効率が低下することによる、現実世界への適用が困難であるという課題もある。本研究の目的は、HIV数理モデルに対して、強化学習の一つであるDeep Q-learningを用いたオンライン強化学習と、実際の患者の臨床データに基づくオフライン強化学習を組み合わせることで、学習過程も安定させた投薬スケジュールを提案することである。

本論文は次のように構成されている。2章では本論文で使用するHIV数理モデルについて示し、3章では強化学習の基本概念と、その手法の一つであるDeep Q-learningを紹介する。4章では、Deep Q-learningを用いたオフライン・オンライン強化学習のシミュレーション結果と従来手法であるQ-learningのシミュレーション結果を示し、比較する。また、Replay memoryをなくした場合についての結果との比較も行う。最後の章では結論と今後の課題を述べる。

2 HIV数理モデル

2章では、本論文において使用するHIV数理モデルおよび、HIV感染メカニズムや投薬の効果について説明する。

HIVウイルスと免疫系の相互作用を表現する数理モデルに関して、多くの研究が行われてきた^{18)~20)}。本論文において使用する数理モデルはPerelson^{21) 22)}によって提案されたものであり、このモデルの特徴はHIVウイルスの複製前期過程と後期過程を4つという少ない状態数で表現しているところである。ウイルス複製後期過程を考慮するモデルを使用することにより、短期ではなく、長期のウイルスと免疫の相互作用を考慮した投薬スケジュールを組むことができる。非線形数理モデルは次の式(1)~(4)で表される。

$$\frac{dX}{dt} = \frac{\lambda}{1+V(t)} - \mu_x X(t) + RX(t) \left(1 - \frac{X+Y+Z}{P_{max}}\right) - k_1 XV, \quad (1)$$

$$\frac{dY}{dt} = k_1 X(t)V(t) - \mu_y Y(t) - k_2 Y(t), \quad (2)$$

$$\frac{dZ}{dt} = k_2 Y(t) - \mu_z Z(t), \quad (3)$$

$$\frac{dV}{dt} = (1-u(t))N\mu_z Z(t) - k_1 X(t)V(t) - \mu_v V(t). \quad (4)$$

本数理モデルにおいて、Xは未感染CD4細胞数、Yは潜伏感染CD4細胞数、Zは活動感染CD4細胞数、Vは遊離ウイルス数を表す。また、制御入力 u は式(4)における $u(t)$ であり、 $[0,1]$ の範囲での投薬量を示している。式(1)~(4)で使用されているパラメータは次の通りである。ここで、式(1)における $\lambda/(1+V(t))$ はCD4細胞の生成数を表し、遊離ウイルス量 V が増加すると、生成数は減少する。また、X~Vには死亡率が $\mu_x \sim \mu_v$ として定義されて

いる。 P_{max} はCD4細胞の最大値であり、X~ZのCD4細胞の合計はこの値を超えてはならない。

λ ,	新たなCD4細胞の生成率
R ,	CD4細胞の成長率
N ,	活動感染細胞Zによって生成される遊離ウイルス数
k_1 ,	遊離ウイルスによりCD4細胞が感染する割合
k_2 ,	潜伏感染細胞Yから活動感染細胞Zに変換する割合
μ_x ,	未感染CD4細胞Xの死亡率
μ_y ,	潜伏感染CD4細胞Yの死亡率
μ_z ,	活動感染細胞CD4細胞Zの死亡率
μ_v ,	遊離ウイルスVの死亡率
P_{max} ,	CD4細胞の最大値

HIV数理モデルにおけるX~Vと投薬量 u の相互関係をFig. 1に示す。また、HIV感染メカニズムは次の通りである。未感染CD4細胞Xに遊離ウイルスVが侵入すると、 $k_1 V(t)X(t)$ が感染し、潜伏感染細胞Yへと変化する。次に、時間の経過とともに潜伏感染細胞Yのうち $k_2 Y(t)$ が活動感染細胞Zへと変化する。活動感染細胞Zは抗体免疫反応により刺激を受けると、死亡するとともに誤って遊離ウイルスを複製してしまう。投薬量 $u(t)$ が作用する段階は、活動感染細胞Zが遊離ウイルスVへと変化する際であり、投薬の効果により遊離ウイルスへと変化する活動感染細胞Zは $u(t)N\mu_z Z(t)$ だけ減少する。




Fig. 1: HIV感染メカニズムと投薬の効果

3 制御手法

3章では、制御手法である強化学習についての基本的な説明および、先行研究¹⁶⁾において使用されたQ-learningアルゴリズム、本研究において使用するDeep Q-Networkを紹介する。次にオフライン強化学習を紹介し、オフライン強化学習とオンライン強化学習を融合した提案手法の説明を行う。

3.1 強化学習

強化学習(Reinforcement Learning)とは、環境(Environment)とエージェント(Agent)の相互作用において特定のタスクを達成するための最適な方法を学習することを目指している²³⁾。状態(state)は一般に特徴量を示しており、環境とエージェントの相互作用の関係を

Fig. 2 に示す. ただし, 赤字部分は本研究における環境, エージェント, action である. 本研究において, エージェントはHIVモデルに対してaction(投薬量)を作用させ, 投薬量が短期的にどれほどの価値をもっているかという指標であるrewardと次のstateを得る. そして得られたstateをもとに薬物管理者は最適なactionを選択する. これを繰り返すことにより, 環境とエージェントの相互作用のなかで, 最適なactionを得られるような方策 π を学習することができる.




Fig. 2: 環境とエージェントの相互作用

強化学習における教師信号を表しているものは, 特定のactionの短期的な価値を表すrewardであるが, 重要なのは短期的な価値が高いことだけが強化学習における目的ではないということである. 実際には, 短期的な価値であるrewardの期待値で定義される価値関数が最大となるようなactionをとることが, 強化学習における目的である. このような, 価値関数を考慮することによって, あらゆるタスクにおいて長期的な価値を重視することが可能になる. 価値関数 V は次の式(5)で定義される¹⁶⁾.

$$V(s) = E \left\{ \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s \right\}, \quad (5)$$

式(5)について, γ は割引率を表し, 将来のrewardをどれほど割り引くかという指標である. したがって, γ が1に近いほど, 現在のrewardを重視し, 0に近いほど将来の報酬を重視することになる. また, あるstateにおいてactionをとったときに見込まれる価値関数である行動価値関数 $Q(s, a)$ は式(6)のように与えられる.

$$Q(s, a) = E \left\{ \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right\}. \quad (6)$$

$P_{ss'}^a(s_k = s, a_k = a, s_{k+1} = s')$ を状態遷移確率, 最適方策 π^* を式(7)と定義するとき, 最適方策 π^* のもとの価値関数 V^* は式(8)のように定義される. ただし, Π は実現可能なあらゆる方策の集合であり, S は状態の集合, A は行動の集合, 報酬関数 $R_{ss'}^a$ は s, a, s' のみに依存し, 即時報酬 r を決める関数であると定義する²⁴⁾.

$$\pi^*(s) = \operatorname{argmax}_{\pi \in \Pi} V^\pi(s) \quad (7)$$

$$V^* = \max_{a \in A} \left[\sum_{s' \in S} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')] \right], s \in S \quad (8)$$

式(8)は最適ベルマン方程式²⁵⁾であり, 唯一解をもつことで知られている. (8)を解くことで導かれる価値数 $Q^*(s, a)$ は次の式(9)-(10)で定義される. また最適行動

価値関数 $Q^*(s, a)$ は, 与えられた状態 s に対する行動 a の良さを評価する指標である.

$$\pi^*(s) = \operatorname{argmax}_{\pi \in \Pi} Q^*(s, a) \quad (9)$$

$$Q^*(s, a) = \sum_{s' \in S} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')] \quad (10)$$

3-2 Q-learning

Q-learningとは強化学習の中でも, 方策 π^* を直接関数として定義するのではなく, 行動価値関数 $Q^*(s, a)$ を更新することで最適方策を導くオフポリシー学習に分類される. Q-learningにおいては, 状態・行動空間を分割し, 特定の状態・行動における行動価値関数 $Q(s, a)$ をQ-Tableという表に格納する. 状態数 $n \in N$, 行動数 $k \in N$ におけるQ-TableをFig. 3に示す.

state	action					
	Action 1	Action 2	...	Action k-1	Action k	
State 1	Q_{11}	Q_{12}	...	Q_{1k-1}	Q_{1k}	
State 2	Q_{21}	Q_{22}	...	Q_{2k-1}	Q_{2k}	
...	...	...	...	...	...	
State n	Q_{n1}	Q_{n2}	...	Q_{nk-1}	Q_{nk}	

Fig. 3 Q-Tableの一例

Q-learningにおいて毎ステップごとに, エージェントは報酬と状態を受け取り, $Q(s, a)$ を更新する. Q 値の更新式は以下の式(11)で定義される.

$$Q(s_t, a_t) = Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \max_{a \in A} Q(s_{t+1}, a) - Q(s_t, a_t)], \quad (11)$$

ここで, α は学習率, つまりエージェントが一度の学習でどれほど Q 値を更新するかという度合いである.

エージェントが行動を選択する際に, はじめから Q 値が最大となる行動をとり続けてしまうと, 学習が不完全な場合に誤った行動を選択してしまうことで, 行動の偏りが生じてしまう. 結果として, より良い行動が存在するにも関わらず, その行動を見逃してしまうことになり兼ねない. そのような行動の偏りを防ぐために, 行動の選択には ϵ -greedy法やSoftMax法が採用される. ϵ -greedy法とは, $0 \leq \epsilon \leq 1$ によって定義されるパラメータ ϵ 以下の確率でランダムな行動をとり, 学習が進むにつれて, ϵ の値を小さくすることで活用と探索のバランスをとるという手法である. 一方で, SoftMax法とは式(12)のような確率で行動を選択する手法である.

$$p(a) = \frac{e^{\frac{Q(s_t, a_t)}{T}}}{\sum_{k=1}^n e^{\frac{Q(s_t, a_k)}{T}}} \quad (12)$$

確率 $p(a)$ に含まれる T は計算温度であり, このパラメータを調整することで Q 値の大きい行動を際立たせたり, 均一化させたりすることが可能になる.

次に, 先行研究¹⁶⁾における状態・行動・報酬の定義を説明する. 状態(state)はHIV数理モデル^{21) 22)}における特徴量である未感染CD4細胞数 X および, 遊離ウイルス量 V の二次元配列で表される. 行動(action)は投薬量および制御入力 u を表しており, $[0, 1]$ を10等分したいずれかの値をとる. 報酬(reward) $r_t(s, a)$ は次の式(12)で表され, 遊離ウイルス量が減少, あるいは投薬量が減少すると報酬が増加する, ウイルス量と副作用を考慮した関数として定義される. ただし, V_{old} ,

$dose_{old}$ は以前のステップにおける遊離ウイルス量、投薬量を、 V_{new} , $dose_{new}$ は現在のステップにおける遊離ウイルス量、投薬量を表している。

$$r_t(s, a) = \log\left(\frac{V_{old}}{V_{new}}\right) - (dose_{new} - dose_{old}) \log(dose_{new}) \quad (13)$$

3-3 Q-TableからDeep Q-Networkへの拡張

Q-learningでは、Fig. 3のように状態・行動空間におけるQ値を格納するが、状態・行動数が増加すると次元の呪いにより実用化が非現実的になってしまうことが懸念されている²⁶⁾。そこで、状態・行動空間を増加させた場合でも、Q値を導くことができるRL手法を採用する必要がある。そのような手法の一つとして広く使用されている、Deep Q-Network (以下、DQNと称する)を説明する。DQN²⁷⁾はQ-learningの改良型アルゴリズムであり、特定の行動に対してQ値を非線形近似することで、Q-learningが高次元の状態・行動空間に適していないという課題を解決することができる。Fig. 4にDQNの模式図を示す。




Fig. 4: DQNの構造

DQNにおいて、ニューラルネットワーク(NN)の入力層に状態(state)を入れたら、NN内部で重み計算をしてQ値を出力として得られる。NNには入力層と中間層(隠れ層)、出力層が含まれ、それぞれの層のnode数を調整したり、隠れ層の数を増減させたりすることで出力から得られるQ値の近似性能や計算負荷を調整することができる。NNに非線形性を持たせる活性化関数にはReLU関数(ランプ関数)を使用し、node数 32 個の隠れ層を 2 層設定した。また、DQNにおいては学習を安定させるために次のような技術を採用した。

3.3.1 Fixed Target Q-Network

Fixed Target Q-Networkとは、DQNのエージェント内部にメインネットワークとは別のネットワークであり、メインネットワークと全く同じ構造を持ち、Q値の予測値を出力するネットワークである。DQNにおいてはQ-learningにおけるQ値の更新式(11)を変形し、予測したQ値と実際のQ値の誤差関数を最小にすることを目標とする。この時損失関数は式(14)で与えられる。またメインネットワークのパラメータを θ 、ターゲットネットワークのパラメータを θ^- とすると、ターゲットネットワークにおける損失関数は式(14)で表される²⁸⁾。ここで $Q'_\pi(s', a', \theta_i)$ はNNの出力として予測したQ値である。

$$L_i(\theta_i) = E \left[\left(r + \gamma \max_{a \in A} Q_\pi(s', a', \theta_i) - Q'_\pi(s, a, \theta_i) \right)^2 \right] \quad (14)$$

$$L_i(\theta_i) = E \left[\left(r + \gamma \max_{a \in A} Q_\pi(s', a', \theta_i^-) - Q'_\pi(s, a, \theta_i) \right)^2 \right] \quad (15)$$

Q-Networkの更新を定期的に行うとともに、Target Networkの更新も定期的に行うことで測定値との誤差を修正する必要がある。メインネットワークおよびターゲットネットワークの構造をFig. 5に示す。




Fig. 5: DQN Agentにおけるnetworkの構成

3.3.2 Experience Replay

Q-learningにおいては現在の状態をもとにQ-Tableが最も高い行動を選択し、その経験を一切利用することができない。結果として、過去の経験を利用することができないことによる行動の偏りが発生し兼ねない。このような現象を防ぐために採用されたのが Experience Replayである。Fig. 6にExperience Replayの構造を示す。




Fig. 6: Experience Replayの仕組み

Experience Replayはstateやreward, actionなどの経験をメモリにpushすることで、メモリの最大数に至るまで経験を貯蓄し、ミニバッチ学習としてランダムに活用することができる仕組みである。ステップ数がバッチサイズを下回る場合は、ミニバッチ学習をすることができないため、モデルの更新は行わない。また、メモリの最大数を上回る経験数が集まると自動的にメモリから経験を捨てるように設定されている。Experience Replayを活用してバッチ学習し、DNN(Deep Neural Network)をトレーニングすることで、オンライン上で得られたデータの相関による学習の不安定性を克服することに期待される²⁹⁾。

3.4 オフライン強化学習

強化学習では、環境をゲームのように正確に定義することは困難であることが多いため、医療分野や精密加工分野などの失敗が許容されない領域において強化学習の利用は進んでいない。そこで、オフライン強化学習という以前に収集されたインタラクションの静的データセットからのみ学習するパラダイムを採用することで、教育や医療、ロボット工学などの幅広い実世界アプリケーションへの応用に期待ができる³⁰⁾。

本研究で使用した医療データは、Stanford University HIV薬物耐性データベース³¹⁾内に保管されている臨床試験³²⁾データである。本臨床試験のデータは具体的には Table 1 のように与えられている。左からPTID(患者番号), Subtype(HIVウイルスの種類), V Load(遊離ウイルス量), CD4Count(CD4 細胞数), Start Date(投薬開始日), Stop Date(投薬終了日), 使用した薬の種類により構成される。PTIDは患者一人一人に割り当てられている。subtypeはHIVウイルスを細かく分類したものであり、大半の患者が当てはまるHIV-1 タイプではAからKの種類に分けることができる³³⁾。投薬の種類にはPI(プロテアーゼ阻害剤)やNRTI(逆転写酵素阻害剤), NNRTI(非核酸系逆転写酵素阻害剤), INSTI(インテグラーゼ阻害剤)の4つに分類される計22種類を候補として使用した。

Table 1 HIV臨床試験データ³²⁾の概要

PTID	subtype	V Load	CD4 Count	Start Date	Stop Date	APV	...	RAL
268298	C	4.9	144	0	40	0	...	1
268298	C	2.6	298	0	40	0	...	0
268298	C	2.6	263	0	40	1	...	0
...	...	...	...	...	...	...	...	...
268763	B	2.6	616	172	244	0	...	1

Fig. 7 に今回使用するオフライン強化学習の概要を示す。オフライン強化学習では、環境との相互作用がないため、フィードフォワード構造をとる。

オフライン強化学習のNNに入力するstateには、未感染CD4 細胞数X, 遊離ウイルス量V, HIV-subtype, Start Date, Stop Dateの5次元配列を使用した。また、actionには5次元の投薬の種類を使用した。具体的には、Table 1 における22種類の投薬の種類及び、無投薬を合わせた23個の数字により構成されるリストとして表現した。つまり、計算コストを考慮し、同期間あたりの投薬の最大の種類を5種類であると仮定したうえで、無投薬の場合は0を、特定の種類の投薬を行う場合はAPV(1)からRAL(22)までの数字をリストに入れることで投薬の種類やその数を表現することが可能になる (offline action)。



Fig. 7: オフライン強化学習の概要

3.5 オンライン強化学習

ここでは本研究で用いるオンライン強化学習の設定について説明する。オンライン強化学習においても3.3章で説明したDQNを用いる。Fig. 8には本研究におけるオンラインAgentとenvironmentの関係を示す。Fig. 8のようにオンライン強化学習ではフィードバック構

造を取り、environmentから得られたstateとrewardはAgentへ渡され、Q値が最大となるactionを ϵ -greedy法で導き (online action), actionをenvironmentへ渡す。これを繰り返すことで学習を進めることができる。




Fig. 8: オンライン強化学習の概要

3.6 オフライン強化学習とオンライン強化学習の融合

ここでは、本研究における提案手法である、オフライン強化学習とオンライン強化学習の融合について説明する。Fig. 9には提案手法の概要を示す。

本研究では、オフライン強化学習とオンライン強化学習を組み合わせることで、CSVデータベースを活用することで学習を安定化させつつ、投薬量だけではなく投薬の種類を導くことを図る。具体的には、CSVデータベースに基づくオフライン強化学習によりoffline actionを導き、オンライン強化学習により環境と作用させることでonline actionを導く。最終的にはfinal actionとしてoffline actionのうち何種類を選択する必要があるか抽出する。次に、環境から得られたstateをオフライン・オンラインAgentに作用させ、それぞれのactionを導く。これを繰り返すことで学習の誤差を修正していくのが本研究における提案手法である。




Fig. 9: 提案手法の全体図

4 数値シミュレーション

本章においては従来手法であるQ-learningおよび提案手法であるDQNの報酬を比較した。具体的には、200人、140日間のrewardの累積や時系列における報酬平均の推移の比較により、長期的に見たactionの価値を評価した。また、DQNにおける学習を安定させるために用いる Experience Replay の効果を把握するために、提案手法と、提案手法からReplay memoryをなくした場合での報酬の比較を行った。シミュレーションに必要なパラメータの設定はTable 2に示す。

Table 2: シミュレーション設定

パラメータ	Q-learning	DQN	Replay memory なし
X初期値	[0,1000]から ランダムな整数	[0,1000]から ランダムな整数	[0,1000]から ランダムな整数
V初期値	[0,5]のうち 1 次 までの小数	[0,5]のうち 1 次 までの小数	[0,5]のうち 1 次 までの小数
割引率 γ	初期:0.5 以降: 0	初期:0.5 以降: 0	初期:0.5 以降: 0
学習率 α	0.5	0.5	0.5
行動選択	SoftMax	ϵ - greedy	ϵ - greedy
状態数	2	5	5
報酬	初期: 0 以降: 式(12)	初期: 0 以降: 式(12)	初期: 0 以降: 式(12)
行動	[0,1]を 10 等分し たもの	[0,1]を 5 等分し たもの	[0,1]を 5 等分し たもの
行動頻度	1 日 1 回	7 日に 1 回	7 日に 1 回

4. 1 従来手法: Q-learning

Fig. 10 には従来手法であるQ-learningを用いた場合の140日間報酬平均(200人)の推移を, Fig. 11には140日間の累積報酬(200人)の結果を示す. ただし累積報酬とは140日間の報酬の和であり, 長期的な報酬の大きさを表している.




Fig. 10: 140 日間報酬平均の推移 (Q-learning)




Fig. 11: 140 日間の累積報酬 (Q-learning)

4. 2 提案手法: Deep Q-learning

Fig. 12 には提案手法であるDQNを用いた場合の140日間報酬平均(200人)の推移を, Fig. 13には140日間の累積報酬(200人)の結果を示す.




Fig. 12: 140 日間報酬平均の推移 (DQN)




Fig. 13: 140 日間の累積報酬 (DQN)

4. 3 比較手法: Deep Q-learning (Replay memoryなし)

Fig. 14 にはDQNからReplay memoryを除いた制御手法を用いた場合の140日間報酬平均(200人)の推移を, Fig. 15には140日間の累積報酬(200人)の結果を示す.




Fig. 14: 140 日間報酬平均の推移 (Replay memoryなし)




Fig. 15: 140 日間の累積報酬 (Replay memoryなし)

4. 4 提案手法による投薬スケジュール

Fig. 16 には提案手法であるDQNにより導いた投薬スケジュールの結果を示す. 導かれた投薬スケジュールは7日に1度変化するものであり, 最大5種類の薬剤のラベルにマーカーが付与される. 水色はoffline

actionを表し、青はonline actionによりさらに種類を絞ったactionを表している。




Fig. 16: DQNによる治療方針

4.5 比較・検討

時系列の報酬の推移について、Fig. 10, Fig. 12 からわかるように、はじめはQ-TableあるいはQ-Networkの初期化が行われるため、報酬は大きく低下する。やがてステップ数が増加するにつれて学習が進み、報酬は0へ近づく挙動を示す。DQN (Fig. 12) では7日に1度しかactionを調整することができないにもかかわらず、時系列報酬平均は、Q-learning: -0.349, DQN: 0.163 とDQNの方が上回っていた。また、Fig. 11 とFig. 13 を比較すると全体的に累積報酬はDQNの方が高く、平均はQ-learning: -48.821, DQN: 22.809 とDQNの方が上回る結果となった。主な要因としては、次のような理由が考えられる。

- DQNはReplay memoryにより過去の経験からサンプリング効率を上げられる
- Q-learningと異なり、状態行動空間を離散化する必要がないため、正確なQ値を導くことができる

一方で、Replay memoryをなくした場合、つまりFig. 12, 14 およびFig. 13, 15 同士で比較すると時系列報酬平均ではDQN: 0.613, Replay memoryなし: -0.043 であり、累積報酬ではDQN: 22.809, Replay memoryなし: -6.071 となった。このようにReplay memoryをなくしてしまうと現在の状態からQ値を導くことができず、より最適な行動を見逃してしまうことが読み取れる。

また、Fig. 16 について臨床試験³²⁾が行われた当時のHIV治療方針と比較すると、全期間のうち6割は当時の治療方針と一致しており、4割は一部の薬剤を医師の判断で補完する必要がある、そのうち1.5割は当時の医療では認められていなかった組み合わせであるが、後の推奨薬として使用されていたものであった。³⁴⁾ 本研究においてオフライン強化学習によって提案された治療方針は、医師の判断する際の材料として使用されることを目的としている。そこで医師の経験や、患者の薬物耐性などから必要な薬を補完することで推奨されている投薬スケジュールを提案することのみならず、今まで採用されていなかったが、より良い薬の組み合わせを開拓する支援をする可能性にも期待できる。

5 結論・今後の課題

本研究において、従来研究¹⁶⁾ではQ-learningを用いてHIVウイルス量を制御していたが、DQNに置き換えることで学習の安定化をもたらすことに成功した。また、臨床試験データに基づく、オフライン強化学習を採用することで投薬量ではなく最適な投薬の種類を提案することに成功した。さらに、オンライン強化学習とオフライン強化学習を組み合わせることで、患者の状態に合わせた最適な投薬量と投薬の種類を動的に提案することにも成功した。これにより、患者の個体差(HIV-subtypeや未感染CD4 細胞数、遊離ウイルス量)に適合した、動的な投薬スケジュールを提案することができ、その結果は医師の意思決定の支援につながるものであった。しかし、依然として次のような課題が残る。

- 今回使用した臨床試験データ³²⁾は患者数が456と少ないためoffline actionに偏りが生じてしまう
- 計算コスト上、offline actionの最大数を5としたが、本来は種類が多いほど医師の判断材料を広げることができる
- 個別化治療に近づけるためには、患者の特徴量を増やす必要があるが、薬物耐性や患者のパラメータが不足している
- HIV数理モデルのパラメータは固定であると仮定しているが、実際には変動する可能性が否定できない

以上のような課題点を克服するために、より多くのサンプル数があり、患者の特徴量をもつデータを活用することができれば、偏りが小さく、患者個人に適合した治療方針を立てることが期待できる。

参考文献

- 1) 服部 俊夫, 小糸 厚, 村上 利夫, 松下 修三, 前田 洋助, 高月 清, 加藤 昌功: エイズウイルスの感染機構, 化学と生物 27 巻 4 号 p.218-227 (1989)
- 2) 小柳義夫, 渡部匡史: HIV 増殖機構と抗 HIV 薬の作用機序, 京都大学ウイルス研究所エイズ研究施設ウイルス病態研究領域 日本臨床 68 (3) 378-381 (2010)
- 3) Strategies for Management of Antiretroviral Therapy (SMART) Study Group, El-Sadr WM, et al: CD4+ count-guided interruption of antiretroviral treatment. N Engl J Med 355(22): 2283/96 (2006)
- 4) Adams et al., 2004, Adams B.M., Banks H.T., Kwon H.-D., Tran H.T. Dynamic multidrug therapies for HIV: Optimal and STI control approaches Math. Biosci. Eng., 1 (2) 223/241 (2004)
- 5) Freedberg et al., 2001 Freedberg K.A., Losina E., Weinstein M.C., Paltiel A.D., Cohen C.J., Seage G.R., Craven D.E., Zhang H., Kimmel A.D., Goldie S.J: The cost effectiveness of combination antiretroviral therapy for HIV disease, N. Engl. J. Med., 344 (11) 824/831(2011)
- 6) Friis-Møller et al., Friis-Møller N., Sabin C.A., Weber R., et al: Combination antiretroviral therapy and the risk of myocardial infarction, N. Engl. J. Med., 349 (21) 1993/2003 (2003)

- 7) <https://viivhealthcare.com/hiv-news-and-media/news/press-releases/2024/march/cabotegravir-long-acting-injectable/>
- 8) B. Adams, H. Banks, M. Davidian, H. Kwon, H. Tran, S. Wynne, E. Rosenberg: HIV dynamics, modeling, data analysis, and optimal treatment protocols, *Journal of Computational and Applied Mathematics* 184 (1) 10/49 (2005)
- 9) D. Bortz, P. Nelson, Model selection and mixed-effects modeling of HIV infection dynamics, *Bulletin of Mathematical Biology* 68 (8) 2005/2025 (2006)
- 10) A. Perelson, P. Nelson, Mathematical analysis of HIV-I: dynamics in vivo, *Siam Review* 3/44 (1998)
- 11) Orellana JM: Optimal drug scheduling for HIV therapy efficiency improvement. *Biomed Signal Process Control* 6:379/386 (2011)
- 12) Augusto FB, Adekunle: AI Optimal control of a two-strain tuberculosis-HIV/AIDS co-infection model. *Bio-systems* 119:20/44 (2014)
- 13) Sutton RS, Barto AG: Reinforcement Learning: An Introduction. Cambridge: The MIT press, (1998)
- 14) Ernst D, Stan G-B, Goncalves J, Wehenkel L: Clinical data based optimal sti strategies for hiv, a reinforcement learning approach. In: 45th IEEE Conference on Decision and Control. New York: IEEE: 667/72 (2006)
- 15) Parbhoo S: A reinforcement learning design for HIV clinical trials. PhD Diss (2014)
- 16) Hossein Gholizade-Narm1, Amin Noori: Control the population of free viruses in nonlinear uncertain HIV system using Q-learning. *International journal of machine learning and cybernetics*, 07, Vol.9 (7),1169/79 (2018)
- 17) NAGATA, Kento, ARAI, Sachiyo: Verifiable Reinforcement Learning Framework by Incremental Estimation of Environmental Model: Achieving Safe AI via Understanding Acquired Polic, *The Japanese Society for Artificial Intelligence Proceedings of the Annual Conference of JSAI*, pp.2E6GS805-2E6GS805 (2024)
- 18) Wodarz D, Nowak MA: Mathematical models of HIV pathogenesis and treatment. *Bio essays* 24:1178/1187(2002)
- 19) Ortega H, Martin-Landrove M: A model for continuously mutant HIV-1. In: *Proceedings of 22nd annual EMBS international conference, Chicago, 1917/1920, 2000* (1999)
- 20) Perelson AS, Nelson PW: Mathematical analysis of HIV-1 dynamics in vivo. *SIAM Rev* 41(1):3/44 (1999)
- 21) Perelson AS: Modeling the interaction of the immune system with HIV, Castillo-Chavez, mathematical and statistical approaches to AIDS epidemiology, (Lect. Notes in Biomath 83, 350/370). Springer, New York, p 1989 (1989)
- 22) Perelson A, Kirschner D, DeBoer R: The dynamics of HIV infection of CD4 T-cells. *Math Biosci* 114/125 (1993)
- 23) R.S. Sutton, A.G. Barto Reinforcement Learning: An Introduction MIT Press (2018)
- 24) 吉本 純一郎, 土谷 健二, 石井 伸: 強化学習の基礎理論と応用, 計測自動制御学会誌 Vol.44(5), 313/318 (2005)
- 25) R.E. Bellman: *Dynamic Programming*, Princeton University Press, Princeton, NJ. (1957)
- 26) Neves, Miguel, Vieira, Miguel, Neto, Pedro: A study on a Q-Learning algorithm application to a manufacturing assembly problem, *Journal of manufacturing systems*, Vol.59, 426/440 (2004)
- 27) Volodymyr M, Koray K, David S, et al.: Human-level control through deep reinforcement learning. *Nature*. 518: 529/533 (2015)
- 28) Volodymyr Mnih1, Koray Kavukcuoglu1, David Silver1, Andrei A. Rusu1, Joel Veness1, Marc G. Bellemare1, Alex Graves1, Martin Riedmiller1, Andreas K. Fidjeland1, Georg Ostrovski1, Stig Petersen1, Charles Beattie1, Amir Sadik1, Ioannis Antonoglou1, Helen King1, Dhharshan Kumaran1, Daan Wierstra1, Shane Legg1 & Demis Hassabis1: Human-level control through deep reinforcement learning, *Nature (London)*, Vol.518 (7540),529/533 (2015)
- 29) Badgwell, Thomas A, Lee, Jay H.: Liu, Kuang-Hung: Reinforcement Learning – Overview of recent progress and implications for process control, *Computer Aided Chemical Engineering*, Vol.44, 71/85 (2018)
- 30) Figueiredo Prudencio, Rafael, Maximo, Marcos R. O. A., Colombini, Esther Luna: A Survey on Offline Reinforcement Learning: Taxonomy, Review, and Open Problems, *IEEE transaction on neural networks and learning systems*, Vol.35 (8),10237/10257 (2024)
- 31) <https://hivdb.stanford.edu/>
- 32) Rami Kantor,1 Laura Smeaton,2 Saran Vardhanabhuti,2 Sarah E. Hudelson,3 Carol L. Wallis,4 Srikanth Tripathy,5 Mariza G. Morgado,6 Shanmugham Saravanan,7 Pa chamuthu Balakrishnan,7 Marissa Reitsma,1 Stephen Hart,8 John W. Mellors,9 Elias Halvas,9 Beatriz Grinsztejn,10 Mina C. Hosseinipour,11 Johnstone Kum wenda,12 Alberto La Rosa,13 UmeshG.Laloo,14 Javier R. Lama,13 Mohammed Rassool,15 Breno R. Santos,16 Khuanchai Supparatpinyo,17 James Hakim,18 Timothy Flanigan,1 Nagalingeswaran Kumarasamy,6 Thomas B. Campbell,19 and Susan H. Eshleman3; for the AIDS Clinical Trials Group (ACTG) A5175 Study Team: Pretreatment HIV Drug Resistance and HIV-1 Subtype C Are Independently Associated With Virologic Failure: Results From the Multinational PEARLS (ACTG A5175) Clinical Trial, *Clin Infect Dis*. 60(10):1541/9 (2015)
- 33) 武部 豊: HIV 分類と命名法の新しいガイドライン:HIV の起源と HIV-1 サブタイプの生物学的相関に関連する問題, *The Japanese Society for Virology Uirusu*, Vol.50(2), 123/138 (2000)
- 34) 塚田訓久: 治療ガイドラインの変遷と現状, *日本エイズ学会誌* 22 : 13/18 (2020)